Big Data & AI in Business — fonti dei dati, tempo della decisione e casi

Copertura verificata. Prima sessione: registrazione PLAUD attribuita a Luca Rizzi, 10:03:20–11:34:20. Seconda sessione: registrazione attribuita dall'orario a Riccardo Campana, 12:03:26–13:05:35. La seconda era programmata fino alle 13:30; non è verificato se il tratto finale si sia svolto o se esista un'altra registrazione. Questi appunti spiegano il contenuto effettivamente registrato e il PDF docente BigDataBsnsRizzi2026Lesson2.pdf (45 pagine, Canvas file 132151). Dove il PDF prosegue oltre l'audio, lo indico espressamente. I nomi dei docenti provengono dall'orario del corso, non dall'identificazione della voce nella trascrizione.

1. Il filo della lezione: dato → decisione → valore

Un'impresa non ha bisogno di raccogliere ogni dato possibile; ha bisogno dei dati che consentono una decisione migliore nel tempo in cui può ancora agire. Il flusso è: definire l'azione, scegliere fonti pertinenti, capire come vengono prodotte, controllarne qualità e diritti d'uso, elaborarle entro la finestra decisionale, confrontare la nuova decisione con una base di riferimento. Il punto comune fra la seconda sessione e i casi della prima è questo: quantità e velocità dei dati non sostituiscono la domanda «che cosa cambieremo grazie al risultato?».

Spiegazione aggiunta, caso ipotetico. Un centro fitness vede che le prenotazioni del corso serale calano. Il conteggio degli accessi dice che cosa accade; orari, disdette e capienza aiutano a capire perché; una previsione stima quali corsi potrebbero riempirsi; solo un responsabile può poi decidere se cambiare orario, istruttore o prezzo. Per sapere se l'analisi è servita, confronta presenze, soddisfazione e margine prima e dopo, considerando altre cause possibili.

2. Da dove arrivano i dati e che cosa possono dire

Le slide 4–11 e la seconda registrazione passano in rassegna persone, processi, macchine e fonti esterne. Non sono categorie intercambiabili: ogni fonte osserva un pezzo diverso del fenomeno.

- Transazioni e sistemi gestionali. Vendite, pagamenti, ordini, ERP e CRM registrano eventi amministrativi e relazioni con clienti. Sono utili per ricostruire che cosa è successo, ma un acquisto non misura automaticamente il desiderio del cliente: prezzi, promozioni, disponibilità e scelta del canale possono averlo influenzato.
- Sensori e macchine. Temperatura, vibrazione, posizione o consumo energetico descrivono stati fisici nel tempo. Un'anomalia può richiedere un controllo, ma un sensore mal calibrato genera falsi allarmi. Servono unità, frequenza, data/ora, identificativo del dispositivo e manutenzione della misura.
- Interazioni digitali e social. Ricerche, click e commenti danno segnali di interesse e contesto. Chi scrive o clicca non rappresenta necessariamente tutti i clienti; bot, campagne e cambi di piattaforma possono alterare il segnale. Un trend osservato non è ancora una previsione di acquisti.
- Dati esterni e API. Meteo, geografia o servizi di terzi possono completare il quadro. Un'API è un'interfaccia con cui un sistema richiede dati o funzioni a un altro. Prima di usarla bisogna verificare licenza, aggiornamento, disponibilità e possibili cambi di formato o costo.

Meccanismo causa-effetto. Più fonti possono migliorare una decisione solo se descrivono lo stesso oggetto e periodo. Se il CRM chiama un cliente con un ID, il sistema vendite con un altro e i dati meteo con un'area geografica troppo ampia, unirli senza regole produce una precisione apparente. Il lavoro reale è allineare identificatori, definizioni, fusi orari e granularità. La domanda da porsi è sempre: quale errore cambierebbe la decisione?

3. Batch e streaming: scegliere in base alla finestra decisionale

Batch processing tratta insiemi di dati in esecuzioni programmate. È adatto quando l'azione può aspettare: payroll, riconciliazioni, chiusura mensile, report periodici. Permette controlli e ricalcoli più semplici. Il suo limite è che una frode o un guasto possono produrre danni prima del prossimo ciclo.

Stream processing tratta eventi man mano che arrivano o con ritardo ridotto. È utile se qualcuno può intervenire rapidamente: blocco di una transazione sospetta, allarme per una macchina, monitoraggio di una rete. Richiede però gestione di duplicati, eventi in ritardo, errori di rete, falsi allarmi e disponibilità continua. «In tempo reale» non significa zero ritardo: misura la latenza dall'evento all'azione utile.

Le slide 12–19 convergono sulla regola: scegliere la latenza minima necessaria alla decisione, non il sistema più veloce per prestigio. Caso ipotetico: per pagare stipendi il giorno 27, elaborare dati ogni notte può bastare. Per fermare una frode che si completa in pochi secondi, la stessa cadenza è inutile. Per entrambi i casi è possibile mantenere un flusso rapido per gli allarmi e un batch per il controllo contabile successivo.

Domanda di richiamo. Che cosa cambia se una segnalazione di frode arriva dieci minuti dopo il pagamento? Non basta dire «streaming è più veloce»: spiega quale azione è ancora possibile, quanto costa un falso blocco e come il sistema controlla l'esito.

4. Caso Rizzi: studiare il rischio di demenza senza confondere associazione e causa

Le slide 31–34 presentano un confronto fra un approccio epidemiologico basato su ipotesi e modelli data-driven, usando lo studio NACC illustrato dal docente. La domanda è se combinare fattori individuali consenta di identificare persone con maggiore rischio osservato; non è «l'AI diagnostica la demenza».

La Lancet Commission 2024 riassume 14 fattori potenzialmente modificabili e stima che intervenire su di essi potrebbe prevenire o ritardare una quota dei casi, circa il 45% nella popolazione studiata. Questa percentuale non è la quota di persone che svilupperà demenza. Lo studio NACC di Arnold e colleghi è diverso: 9.606 partecipanti, 877 conversioni (9%) nel campione, 13 fattori analizzati e follow-up medio intorno a sei anni. Non sommare o scambiare i 14 fattori della Commissione con i 13 dello studio.

Nel confronto illustrato nelle slide compaiono XGBoost, SHAP e analisi di sopravvivenza. XGBoost costruisce un modello predittivo da combinazioni di variabili; SHAP aiuta a descrivere quali variabili hanno contribuito alle stime del modello, non dimostra che cambiare una variabile causi un miglioramento. L'analisi di sopravvivenza studia il tempo fino a un evento, tenendo conto delle persone che non hanno l'evento osservato entro la fine dello studio. Sono strumenti con domande e ipotesi differenti.

L'articolo originale riporta ROC AUC 0,732, sensibilità 0,702, specificità 0,637, accuratezza 0,643 e PR AUC 0,208. Sensibilità significa quota dei veri casi identificati; specificità, quota dei non casi riconosciuti. Nessuna delle due equivale all'accuratezza totale. Una AUC non dà da sola la probabilità personale di ammalarsi. La bassa prevalenza nel campione, la composizione di volontari dei centri di ricerca e l'assenza di validazione esterna limitano l'uso individuale. Il modello delle slide non è un test clinico pronto.

Il BMI più alto risultava associato a minor rischio osservato in quel campione. Non segue che aumentare di peso prevenga la demenza. La perdita di peso può precedere una diagnosi e creare causalità inversa; una grande analisi con follow-up diversi mostra che l'associazione cambia con l'orizzonte temporale. La Commissione considera l'obesità nella mezza età un fattore di rischio. Questo caso serve a imparare perché non si converte una correlazione in consiglio sanitario.

Applicazione. Prima di usare un punteggio di rischio, chiedi: qual è la popolazione di sviluppo? È stato validato su persone simili a quelle per cui lo useremo? Quanti falsi positivi e falsi negativi produce? Quale intervento sicuro segue il risultato? Se non sai rispondere, un numero apparentemente preciso può peggiorare la decisione.

5. Altri casi della prima sessione: quali dati, quale limite

Grandine e alluvioni, slide 35–37. Per stimare e gestire il rischio assicurativo si possono combinare meteo, geografia, esposizione dei beni e sinistri. L'assicuratore può decidere come prevenire o liquidare, ma una mappa meteo non descrive da sola i danni di un immobile: servono posizione accurata, vulnerabilità, franchigie e verifica. La presentazione è un caso didattico; la registrazione non basta a provare l'esatta architettura o i

risultati di una compagnia specifica. Trasferimento: se un evento estremo è raro, una media storica locale può sottostimare il rischio; descrivi come verificheresti copertura temporale e cambiamento climatico prima di promettere una previsione.

Arte e ambiente, slide 38–40. DATALAND descrive ufficialmente Machine Dreams: Rainforest di Refik Anadol a Los Angeles: il Large Nature Model usa grandi raccolte di dati ecologici, con segnali ambientali e presenza dei visitatori per un'esperienza multisensoriale. L'organizzazione parla di oltre 1,2 miliardi di punti di dati ecologici. Il valore didattico è distinguere input (dati e sensori), trasformazione (modello e visualizzazione) e output (esperienza dell'utente). Un'opera immersiva non prova da sola che un modello comprenda la natura né che ogni numero della presentazione coincida con quelli dell'intera mostra.

Moda, slide 41–43. Segnali di ricerca, social, acquisto e disponibilità possono suggerire un trend; il team può usarli per decidere assortimento e tempi di produzione. Ma chi pubblica foto non è un campione casuale di clienti e una promozione può gonfiare artificialmente la domanda osservata. Il riferimento orale a Zara illustra la logica, non certifica un sistema proprietario specifico. Per provarne l'utilità confronta decisioni prese con e senza il segnale, margine, resi e invenduto.

Centro fitness, slide 44–45. L'esercizio del docente richiede 8–10 touchpoint con dati, fonte e possibile uso; una mappa dei passaggi; due problemi di qualità; un rischio privacy; due opportunità. Esempio ipotetico: sito (pagine e click), iscrizione (piano e contatti), accesso (orario), prenotazione corso (capienza), cancellazione, acquisto personal training, app (interazioni), assessment (misure delicate). La mappa deve mostrare dove i dati entrano e chi può usarli. Duplicati nelle iscrizioni e accessi non registrati sono problemi di qualità; raccogliere dati di salute senza scopo, base giuridica e accessi proporzionati è un rischio da valutare. Opportunità plausibili sono migliorare orari e ridurre cancellazioni; vanno testate, non date per realizzate.

6. Databricks: distinguere dimostrazione prevista e svolta

Le slide 20–29 presentano Databricks come piattaforma unificata per data engineering, analytics e AI, con notebook collaborativi, strumenti cloud, catalogo e query SQL. Prevedono navigazione, importazione CSV, creazione di volume/tabella e visualizzazione di dati. La registrazione disponibile della seconda sessione arriva soltanto alla introduzione di Databricks, intorno al minuto 61. Non posso attribuire al docente una prova pratica o istruzioni eseguite dopo quel momento.

Come studio delle slide, il percorso concettuale è: caricare un file di dati con provenienza chiara → conoscere colonne e tipi → registrarlo nel catalogo con permessi → interrogare la tabella con SQL → controllare qualità e significato del risultato → condividere il notebook con chi decide. SELECT * mostra tutte le colonne ma non spiega se il dataset sia completo o affidabile. Il PDF è una traccia della possibile esercitazione; prima di sostenere di saper ripetere i clic precisi occorre la registrazione o una prova nell'ambiente del corso.

7. Definizioni e metodo di ripasso

- Data source: origine identificabile di un dato, con processo di produzione, aggiornamento e limiti.
- ERP / CRM: sistemi che registrano processi aziendali / relazioni e interazioni con clienti; i dati dipendono da come le persone usano il sistema.
- API: interfaccia per richiedere dati o funzioni a un servizio; non garantisce qualità o diritti d'uso.
- Batch / streaming: elaborazione a intervalli / di eventi in arrivo; la distinzione è legata a latenza e intervento possibile.
- Latency: tempo fra evento, disponibilità del dato, analisi e azione. Il ritardo tecnico è solo una parte.
- Sensitivity / specificity: quota di casi positivi identificati / quota di casi negativi riconosciuti; dipendono dalla soglia di classificazione.
- ROC AUC: misura di discriminazione lungo diverse soglie; non misura da sola calibrazione, causalità o utilità clinica.
- SHAP: metodo per attribuire contributi alle caratteristiche di una previsione; non identifica automaticamente cause.
- Reverse causality: situazione in cui un esito imminente cambia un fattore che sembra predirlo.

- Data catalog: inventario di dataset, significato, provenienza e permessi, necessario per trovare e usare dati senza confonderli.

Richiamo a libro chiuso. Spiega in due minuti perché una catena di supermercati potrebbe usare batch per la contabilità e streaming per un possibile pagamento fraudolento. Poi elenca per il centro fitness tre fonti, un problema di qualità e una decisione concreta. Se riesci solo a nominare gli strumenti ma non l'azione e il rischio, riparti dalle sezioni 1–3.

Caso nuovo, ipotetico. Una società di autobus riceve GPS ogni 10 secondi, reclami alla fine della corsa e fatture una volta al mese. Deve ridurre i ritardi domani mattina. Quali dati useresti subito, quali dopo e che cosa controlleresti prima di cambiare orari? Feedback: GPS può sostenere un allarme tempestivo solo se coordinate e timestamp sono affidabili e se il personale può intervenire; i reclami spiegano problemi percepiti ma arrivano tardi e sono selettivi; le fatture servono a valutare costi, non a correggere il ritardo imminente. Confronta gli orari cambiati con corse simili e considera traffico e meteo.

8. Fonte e limiti della versione

L'originale del docente è Canvas file 132151, archivio canonico Materiale/BigDataBsnsRizzi2026Lesson2.pdf. Le due trascrizioni pulite sono in Lezioni/2026-09-29/transcript/; i passaggi ASR incerti non sono diventati citazioni. I dati dello studio sulla demenza sono controllati sui lavori primari collegati sopra; gli esempi senza azienda e risultato verificati sono indicati come didattici o ipotetici. Le slide non dimostrano che l'esercitazione Databricks sia stata svolta nella porzione non registrata. Gli audio originali delle due registrazioni sono archiviati e verificati per durata e hash. L’eventuale segmento finale della seconda sessione non è verificato: questi appunti coprono integralmente le due registrazioni disponibili e il PDF docente, senza attestare una porzione di lezione non documentata.