Big Data & AI in Business (HFARM502)

16 esercizi originali con risposte ragionate, basati sulle slide locali Lessons 1–4

Esercizi plausibili di allenamento, non domande ufficiali. Rispondi in inglese prima di leggere il modello. Nessun voto automatico o tempo indicato in questo documento equivale alla valutazione ufficiale.

Formato della valutazione: cosa risulta dalle fonti

Confermato:

• Il syllabus ufficiale collegato da Canvas, letto il 19 ottobre 2026, assegna 80% al blog di 3.200 parole e 20% a due prove in classe da 10% ciascuna (pp.2–4).

• Il syllabus colloca i due touchpoint nelle settimane 3–6 e 6–10 e prevede un avviso del docente una settimana prima (p.3).

• Lesson 4 p.41 mostra un warm-up test svolto in classe su AI & Big Data fundamentals: 15 domande, 4 opzioni per domanda e 3 livelli di difficoltà. È una slide di esercitazione, non la specifica della prova valutata.

Da confermare:

• Data, durata, domande e formato concreto del prossimo midterm valutato non sono confermati nei materiali letti. Il warm-up di Lesson 4 p.41 (15 domande, 4 opzioni, 3 livelli) non ne stabilisce il formato. Le alternative del syllabus sono esempi: il test di 20 domande a scelta multipla è indicato solo per L4, mentre questo corso è L5.

Indice · 16 domande

01. Why does having more data not automatically lead to a better business decision? Give a concrete decision chain.

02. Compare structured, semi-structured and unstructured data using one business example for each. What does the label not tell you?

03. A retailer asks what happened, why sales fell, what may happen next, and what action to take. Match each question to an analytics type and state one limit.

04. A chain of gyms sees 30 bookings and 20 recorded entries for an evening class. Should it cut ten seats? Build a responsible data-based answer.

05. For the gym in Lesson 2, propose eight data touchpoints. For each, explain what is collected, where it comes from, and one decision it could support.

06. When should a business choose batch processing rather than streaming? Use a specific operational decision.

07. You imported a CSV into Databricks and SELECT * returned rows. What must you verify before showing a dashboard to a manager?

08. Define a machine-learning problem using Task, Performance and Experience for predicting membership cancellation.

09. Classify three tasks as supervised, unsupervised or reinforcement learning: predicting labelled fraud, finding customer groups without labels, and learning actions from rewards.

10. A model identifies apples in training images with 99% accuracy. Why may this fail after deployment, and how would you test it?

11. Explain the relation between AI, machine learning, deep learning, generative AI and large language models without treating them as synonyms.

12. A company wants to store app events, invoices and images in one data lake. Describe a minimal architecture and the governance controls it needs.

13. Choose between CSV, XML, JSON and Parquet for four tasks: a flat human-edited export, a strict nested message, an API event, and large analytical scans. Explain the trade-offs.

14. A dashboard joins sales, customer, product and forecast files but shows a 25% revenue increase. What would you check before presenting that claim?

15. A team says a recommendation model proves its messages cause customers to buy more. What are the three different claims hidden in that sentence?

16. Why is a model or dashboard not 'finished' at deployment? Propose a monitoring plan for one business use case.

01 · Risposta breve

Why does having more data not automatically lead to a better business decision? Give a concrete decision chain.

Prima prova a rispondere in inglese, poi confronta il modello.

Risposta modello · italiano

La quantità aiuta solo se i dati sono pertinenti, affidabili e possono cambiare una scelta. Parti da una decisione concreta, ad esempio quante persone assegnare ai corsi serali; definisci una metrica e una baseline, controlla qualità e diritti d'uso dei dati, scegli un'analisi proporzionata, inserisci il risultato nel lavoro del responsabile e misura l'esito dopo l'adozione. Un milione di click non misura le presenze se non è collegato a prenotazioni e accessi affidabili. La catena delle slide è frame → acquire → build → adopt → monitor: il valore nasce quando l'ultimo passaggio informa la decisione successiva.

Model answer · English

Volume alone is not value. Define the decision and outcome, acquire relevant data with usage rights, test quality, build an appropriate method, put it into the manager's workflow, and monitor the result against a baseline. Clicks cannot stand in for attendance unless the link to valid bookings and entries is reliable.

Perché è plausibile

La prima lezione insiste sul valore decisionale e dedica le ultime due slide a un framework e tre errori da evitare.

Errore frequente

Equiparare volume a utilità o fermarsi alla dashboard senza verificare una decisione e il suo esito.

Fonte e localizzatore

2026-09-25__big-data-week-1-rizzi-aggiornato.pdf · pp.22, 39, 60–61

Checklist di autovalutazione

- ☐ Decisione e beneficiario
- ☐ Metrica e baseline
- ☐ Qualità e diritti
- ☐ Adozione
- ☐ Monitoraggio

02 · Risposta breve

Compare structured, semi-structured and unstructured data using one business example for each. What does the label not tell you?

Prima prova a rispondere in inglese, poi confronta il modello.

Risposta modello · italiano

Un record CRM con colonne fisse di ID, piano e data è strutturato. Un evento JSON dell'app, con campi comuni ma attributi opzionali, è semi-strutturato. Una registrazione audio di una chiamata è non strutturata rispetto a una tabella relazionale. La classificazione descrive il modo in cui il dato è organizzato; non dice se è vero, completo, lecito da usare o utile alla decisione. Anche un CSV può essere tabellare e ben strutturato se lo schema è definito: l'esempio della slide che lo chiama semi-strutturato non è una regola universale.

Model answer · English

A fixed-column CRM table is structured; an app JSON event with optional fields is semi-structured; a call recording is unstructured for relational analysis. These labels describe organization, not truthfulness, completeness, permission, or business value. CSV may represent structured tabular data when its schema is defined.

Perché è plausibile

Le tre forme sono un nucleo esplicito della Week 1, poi riappaiono in data lake e formati.

Errore frequente

Trattare il formato del file come prova di qualità o assumere che ogni CSV sia per definizione semi-strutturato.

Fonte e localizzatore

2026-09-25__big-data-week-1-rizzi-aggiornato.pdf; canvas-133640__BigDataBsnsRizzi2026Lesson4.pdf · Week 1 pp.33–35; Lesson 4 pp.3, 16–23

Checklist di autovalutazione

- ▫ Tre esempi
- ▫ Struttura distinta da qualità
- ▫ Schema CSV condizionale

03 · Classificazione

A retailer asks what happened, why sales fell, what may happen next, and what action to take. Match each question to an analytics type and state one limit.

Prima prova a rispondere in inglese, poi confronta il modello.

Risposta modello · italiano

'Che cosa è successo?' è descrittiva: ad esempio vendite per settimana. 'Perché?' è diagnostica: confronti stock-out, prezzo e canale, senza chiamare causale una semplice correlazione. 'Che cosa può accadere?' è predittiva: una stima con intervallo d'incertezza su dati storici. 'Che cosa fare?' è prescrittiva: confronta azioni, vincoli e costi, magari con test. Ogni passaggio dipende da dati affidabili e da ipotesi esplicite; la previsione non sceglie da sola l'obiettivo aziendale.

Model answer · English

Descriptive analytics reports what happened; diagnostic analytics explores why; predictive analytics estimates future outcomes; prescriptive analytics recommends actions under objectives and constraints. Correlation is not automatically causation, and a forecast does not choose the business objective.

Perché è plausibile

Le quattro domande sono esplicite nelle slide e si prestano a un esercizio breve di classificazione e applicazione.

Errore frequente

Chiamare ogni grafico 'predictive' o trasformare una correlazione in causa.

Fonte e localizzatore

2026-09-25__big-data-week-1-rizzi-aggiornato.pdf · pp.52–54

Checklist di autovalutazione

- ▫ Quattro tipi
- ▫ Un esempio
- ▫ Limite causale
- ▫ Decisione distinta dalla previsione

04 · Caso applicativo

A chain of gyms sees 30 bookings and 20 recorded entries for an evening class. Should it cut ten seats? Build a responsible data-based answer.

Prima prova a rispondere in inglese, poi confronta il modello.

Risposta modello · italiano

Il no-show apparente è (30−20)/30 = 33,3%, assumendo 30 prenotazioni valide e accessi collegati correttamente. Non taglierei subito dieci posti. Controllerei cancellazioni, lista d'attesa, persone entrate senza scansione e duplicati; confronterei più lezioni, orari e capienza effettiva. La decisione può essere una prova limitata di overbooking o reminder, con baseline di presenze, rifiuti e soddisfazione, e una regola di stop se aumentano i clienti respinti. Dati sanitari raccolti per wellness non vanno riutilizzati per marketing soltanto perché sono tecnicamente collegabili.

Model answer · English

The apparent no-show rate is 10/30 = 33.3%, conditional on valid bookings and matched scans. Check cancellations, waitlists, missing scans, duplicates, and variation across classes before cutting capacity. Pilot a reminder or cautious overbooking against attendance and refusal baselines, with a stop rule. Do not repurpose wellness data without a valid purpose and controls.

Perché è plausibile

È una trasformazione dell'esercizio fitness assegnato nelle slide, non una traccia ufficiale del 10%.

Errore frequente

Sottrarre 10 posti da una singola osservazione e ignorare scansioni mancanti o privacy.

Fonte e localizzatore

BigDataBsnsRizzi2026Lesson2.pdf; 2026-09-25__big-data-week-1-rizzi-aggiornato.pdf · Lesson 2 pp.44–45; Week 1 pp.56–61

Checklist di autovalutazione

- ☐ Formula e assunzione
- ☐ Due rischi di qualità
- ☐ Privacy
- ☐ Baseline e prova
- ☐ Stop rule

05 · Caso applicativo

For the gym in Lesson 2, propose eight data touchpoints. For each, explain what is collected, where it comes from, and one decision it could support.

Prima prova a rispondere in inglese, poi confronta il modello.

Risposta modello · italiano

Esempio ipotetico: 1 visita sito→pagina vista/web analytics→domanda; 2 registrazione→piano/CRM→segmentazione di servizio; 3 prenotazione corso→slot/app→capienza; 4 cancellazione→tempo/app→lista d'attesa; 5 ingresso→timestamp/tornello→presenze; 6 pagamento→stato/POS→incassi; 7 uso attrezzi→evento/sensore, se lecito→manutenzione; 8 feedback→valutazione/questionario→qualità. Serve un ID pseudonimo e regole sullo scopo per collegare fonti; dati sanitari di un assessment richiedono una valutazione separata. Registrazione, prenotazione e presenza non sono la stessa misura.

Model answer · English

A hypothetical map can include website visits, registration, class booking, cancellation, entry scan, payment, equipment event, and feedback. For each, name the field, source system, and decision. Join only with justified identifiers and purposes; a booking is not attendance, and health data require separate safeguards.

Perché è plausibile

La slide chiede esplicitamente 8–10 touchpoint con campo, fonte e uso aziendale.

Errore frequente

Elencare fonti senza dati osservabili o inventare che tutte siano già disponibili/riutilizzabili.

Fonte e localizzatore

BigDataBsnsRizzi2026Lesson2.pdf · p.45

Checklist di autovalutazione

- ☐ Otto touchpoint
- ☐ Dato osservato
- ☐ Sistema fonte
- ☐ Uso decisionale
- ☐ Join e scopo

06 · Confronto

When should a business choose batch processing rather than streaming? Use a specific operational decision.

Prima prova a rispondere in inglese, poi confronta il modello.

Risposta modello · italiano

Per un report vendite mensile, elaborare ogni notte in batch può bastare: tollera latenza e spesso semplifica costi e controlli. Per allertare una frode durante un pagamento, eventi in streaming possono servire perché la decisione deve arrivare in secondi. La scelta dipende da finestra utile della decisione, volume, affidabilità, costi e gestione degli errori; 'più veloce' non è automaticamente migliore. In entrambi i casi occorre deduplicare eventi e monitorare ritardi.

Model answer · English

Nightly batch may fit monthly sales reporting; streaming fits a fraud alert that must act during a payment. Choose based on decision latency, reliability, cost, and error handling, not speed alone. Deduplicate and monitor late events in either pipeline.

Perché è plausibile

La Lesson 2 contrappone batch e streaming; Week 1 ne spiega il trade-off operativo.

Errore frequente

Scegliere streaming per ogni caso perché appare tecnologicamente avanzato.

Fonte e localizzatore

BigDataBsnsRizzi2026Lesson2.pdf; 2026-09-25__big-data-week-1-rizzi-aggiornato.pdf · Lesson 2 p.12; Week 1 p.57

Checklist di autovalutazione

- ▫ Decisione
- ▫ Latenza
- ▫ Costo/complessità
- ▫ Qualità eventi

07 · Metodo applicato

You imported a CSV into Databricks and SELECT * returned rows. What must you verify before showing a dashboard to a manager?

Prima prova a rispondere in inglese, poi confronta il modello.

Risposta modello · italiano

`SELECT *` prova solo che si leggono righe. Controllo schema e significato dei campi, tipi, unità, timestamp e fuso, valori mancanti, duplicati, outlier, row count prima/dopo trasformazioni, chiavi non abbinate nei join, totali di controllo e diritti d'uso. Scelgo poi poche metriche collegate alla decisione e faccio verificare un campione di record. La dashboard deve esporre periodo, popolazione, definizione e limiti, altrimenti un grafico preciso può raccontare una storia sbagliata.

Model answer · English

Readable rows are only the start. Check schema, units, timestamps, missing values, duplicates, join keys, row counts, reconciliation totals, and usage rights. Define the dashboard metric and population, inspect sample records, and show the period and limits before management acts.

Perché è plausibile

Le slide mostrano l'import e l'SQL, mentre la Lesson 4 richiede un checkpoint umano sui risultati generati.

Errore frequente

Scambiare la riuscita della query per validazione semantica dei dati.

Fonte e localizzatore

BigDataBsnsRizzi2026Lesson2.pdf; canvas-133640__BigDataBsnsRizzi2026Lesson4.pdf · Lesson 2 pp.28–29; Lesson 4 pp.24–25

Checklist di autovalutazione

- ☐ Schema e unità
- ☐ Missing/duplicati
- ☐ Row count
- ☐ Join e totali
- ☐ Diritti
- ☐ Decisione

08 · Concetto

Define a machine-learning problem using Task, Performance and Experience for predicting membership cancellation.

Prima prova a rispondere in inglese, poi confronta il modello.

Risposta modello · italiano

Task T: prevedere, per ogni abbonamento attivo a una data di riferimento, se sarà cancellato nei successivi 30 giorni. Performance P: per esempio precision/recall o costo degli errori su un periodo di test successivo, con soglia e costo del contatto; l'accuracy da sola inganna se le cancellazioni sono rare. Experience E: dati storici di prenotazioni, accessi e cancellazioni etichettate disponibili prima della data di previsione. Escludo informazioni successive al momento della decisione, per evitare leakage. Un intervento commerciale va testato separatamente: prevedere chi cancella non dimostra che un messaggio cambierà il comportamento.

Model answer · English

T is predicting cancellation within the next 30 days for an active member at a defined date. P should reflect false-positive and false-negative costs, such as precision and recall on later data. E is historical, labelled pre-decision records. Prevent leakage, and test whether an intervention changes behavior separately from risk prediction.

Perché è plausibile

La Lesson 3 insegna espressamente a formulare T, P, E a partire da un problema aziendale.

Errore frequente

Dire soltanto 'usare ML per churn' senza definire orizzonte, misura ed esperienza; usare dati futuri come feature.

Fonte e localizzatore

BigDataBsnsRizzi2026Lesson3.pdf · pp.6–10

Checklist di autovalutazione

- ☐ T e orizzonte
- ☐ P con costo errori
- ☐ E pre-decisione
- ☐ No leakage
- ☐ Predizione vs effetto intervento

09 · Classificazione

Classify three tasks as supervised, unsupervised or reinforcement learning: predicting labelled fraud, finding customer groups without labels, and learning actions from rewards.

Prima prova a rispondere in inglese, poi confronta il modello.

Risposta modello · italiano

Frode con esempi etichettati: supervised learning; gruppi di clienti senza etichette: unsupervised; azioni successive apprese da ricompense: reinforcement. Con poche etichette e molti dati grezzi si può valutare il semi-supervised, sempre con verifica sul problema reale. Nel caso frode, la classificazione restituisce score/classe, non una decisione automaticamente giusta: un falso positivo blocca una transazione lecita, un falso negativo lascia passare una frode. Precision misura quante segnalazioni sono vere; recall quante frodi reali vengono trovate. Soglia e metriche dipendono dal costo dei due errori, soprattutto se la frode è rara. Un cluster non è già un segmento utile e una ricompensa mal scelta può incentivare azioni sbagliate.

Model answer · English

Labelled fraud prediction is supervised learning; unlabelled customer grouping is unsupervised; learning sequential actions from rewards is reinforcement learning. Semi-supervised learning may help with few labels. In fraud classification, a false positive blocks a legitimate payment and a false negative misses fraud. Precision asks how many flags were true; recall asks how many real frauds were caught. Set the threshold against error costs, especially for a rare class. Clusters and rewards still need business validation.

Perché è plausibile

Lesson 3 espone i tipi di apprendimento; Lesson 4 illustra la classificazione frodi, matrice di confusione, precision/recall e costo dei due errori.

Errore frequente

Confondere il tipo di apprendimento con la capacità analitica; usare la sola accuracy quando la frode è rara o ignorare il costo diverso di falsi positivi e negativi.

Fonte e localizzatore

BigDataBsnsRizzi2026Lesson3.pdf; canvas-133640__BigDataBsnsRizzi2026Lesson4.pdf · Lesson 3 pp.12–19; Lesson 4 pp.29,36

Checklist di autovalutazione

- ▫ Etichette
- ▫ Assenza etichette
- ▫ Ricompensa sequenziale
- ▫ FP/FN
- ▫ Precision/recall e costo errori

10 · Ragionamento critico

A model identifies apples in training images with 99% accuracy. Why may this fail after deployment, and how would you test it?

Prima prova a rispondere in inglese, poi confronta il modello.

Risposta modello · italiano

Il 99% sul training può essere memorizzazione o un indizio spurio, per esempio uno sfondo bianco ricorrente. Provo foto nuove e realistiche, luci/sfondi diversi e sottogruppi; confronto modello semplice e complesso sulla stessa metrica e monitoro gli errori dopo il deploy. Evito il data leakage nelle variabili di input: al momento della previsione il modello non deve ricevere informazioni disponibili solo in seguito o informazioni riservate al test. Gli esiti osservati servono come etichette dei casi storici e per misurare gli errori, ma non come input della previsione che li anticipa. Per una previsione futura divido i dati nel tempo e misuro su casi successivi mai visti; la complessità del modello non corregge dati inaffidabili.

Model answer · English

A 99% training score may reflect memorization or a spurious background cue. Test on held-out realistic photos across lighting, backgrounds and subgroups; compare a simple model, then monitor drift. Prevent data leakage in model inputs: use only information available at prediction time and keep test information out of training. Observed outcomes legitimately serve as historical training labels and for evaluation; they must not become inputs to the earlier prediction. For future forecasting, train on earlier data and test on later unseen cases. Complexity cannot fix flawed data.

Perché è plausibile

Le slide confrontano albero, rete e spiegabilità; Lesson 4 p.35 esplicita la prova “could we know this before making the decision?” contro il leakage temporale.

Errore frequente

Usare accuracy sul training o informazioni future come prova di prestazione reale.

Fonte e localizzatore

BigDataBsnsRizzi2026Lesson3.pdf; 2026-09-25__big-data-week-1-rizzi-aggiornato.pdf; canvas-133640__BigDataBsnsRizzi2026Lesson4.pdf · Lesson 3 pp.28–30; Week 1 p.61; Lesson 4 p.35

Checklist di autovalutazione

- ▢ Test separato
- ▢ Indizi spuri
- ▢ Sottogruppi
- ▢ Nessun dato futuro/leakage
- ▢ Monitoraggio

11 · Concetto

Explain the relation between AI, machine learning, deep learning, generative AI and large language models without treating them as synonyms.

Prima prova a rispondere in inglese, poi confronta il modello.

Risposta modello · italiano

AI è la famiglia ampia di sistemi che svolgono compiti intelligenti, anche con regole esplicite. ML apprende pattern da esperienza/dati; deep learning è una famiglia di ML basata su reti profonde. Generative AI produce contenuti nuovi secondo un modello appreso; un LLM è un modello linguistico, spesso basato su transformer, che genera sequenze di token. Un modello predittivo di frode può essere ML senza essere generativo; un sistema a regole può essere AI senza ML. Un LLM che scrive testo plausibile non certifica che i fatti siano veri.

Model answer · English

AI is the broad field and may include rules. ML learns patterns from data; deep learning is a neural-network family within ML. Generative AI produces new content; an LLM is a language model that generates token sequences. A fraud classifier need not be generative, and fluent LLM output is not factual verification.

Perché è plausibile

La Lesson 3 dedica una sezione alla distinzione e al funzionamento linguistico.

Errore frequente

Usare AI, ML e LLM come sinonimi o presentare un LLM come database di fatti garantiti.

Fonte e localizzatore

BigDataBsnsRizzi2026Lesson3.pdf · pp.24–35

Checklist di autovalutazione

- ▫ Relazione fra famiglie
- ▫ Esempio non generativo
- ▫ Token
- ▫ Verifica fatti

12 · Metodo applicato

A company wants to store app events, invoices and images in one data lake. Describe a minimal architecture and the governance controls it needs.

Prima prova a rispondere in inglese, poi confronta il modello.

Risposta modello · italiano

Definisco ingestion per fonti batch e real-time, storage per dati nativi con ID e metadata, un passaggio di pulizia/distillazione per creare tabelle analitiche, un layer di query/insight e monitoraggio delle operazioni. Registro origine, trasformazioni e responsabili (lineage), qualità, accessi autorizzati, retention e audit. Il lago non diventa utile perché contiene tutto: senza catalogo, definizioni e controlli, l'analista può unire dati incompatibili o sensibili e produrre risultati fuorvianti. Il warehouse può coesistere per dati curati e domande ripetibili.

Model answer · English

Ingest native batch and real-time sources, store them with identifiers and metadata, distill curated analytic tables, expose governed query/insight access, and monitor operations. Track lineage, quality, permissions, retention, and changes. A lake without catalog and governance can become unusable or unsafe; a warehouse may coexist for curated workloads.

Perché è plausibile

Data lake, livelli architetturali, governance e maturità occupano molte slide nelle Lessons 3–4.

Errore frequente

Dire che 'salvare tutto' basta o che data lake e warehouse si escludono.

Fonte e localizzatore

BigDataBsnsRizzi2026Lesson3.pdf; canvas-133640__BigDataBsnsRizzi2026Lesson4.pdf · Lesson 3 pp.36–48; Lesson 4 pp.2–14

Checklist di autovalutazione

- ☐ Ingestion
- ☐ Storage/metadata
- ☐ Curated layer
- ☐ Lineage
- ☐ Accesso e audit
- ☐ Qualità

13 · Confronto

Choose between CSV, XML, JSON and Parquet for four tasks: a flat human-edited export, a strict nested message, an API event, and large analytical scans. Explain the trade-offs.

Prima prova a rispondere in inglese, poi confronta il modello.

Risposta modello · italiano

CSV è semplice e modificabile per la tabella piatta, ma i tipi sono impliciti ed escaping/locale vanno controllati. XML è verboso ma adatto a messaggi gerarchici con schema e validazione rigorosa. JSON è naturale per oggetti e array di API/eventi, con flessibilità ma ripetizione delle chiavi e possibili versioni diverse. Parquet è binario colonnare e compresso, efficiente quando il motore legge poche colonne su grandi volumi, ma non è pensato per l'editing umano. La scelta dipende da forma, utenti e workload, non da una classifica universale.

Model answer · English

Use CSV for flat human-editable exchange, XML for strictly validated nested messages, JSON for API objects/events, and Parquet for large column-oriented analytic scans. CSV needs type and escaping care; XML is verbose; JSON can repeat keys and vary by version; Parquet is efficient but not human-editable. Choose for fit.

Perché è plausibile

La Lesson 4 confronta esplicitamente i quattro formati in tabella e propone una regola di scelta.

Errore frequente

Dire che Parquet è sempre migliore o che JSON è sempre un database analitico.

Fonte e localizzatore

canvas-133640__BigDataBsnsRizzi2026Lesson4.pdf · pp.16–23

Checklist di autovalutazione

- ▫ Quattro assegnazioni
- ▫ Trade-off
- ▫ Tipi/schema
- ▫ Workload

14 · Caso applicativo

A dashboard joins sales, customer, product and forecast files but shows a 25% revenue increase. What would you check before presenting that claim?

Prima prova a rispondere in inglese, poi confronta il modello.

Risposta modello · italiano

Verifico che ID cliente e prodotto siano standardizzati, date/valuta/quantità/prezzo abbiano unità coerenti, righe duplicate e resi siano trattati, e che i join non moltiplichino vendite. Confronto numero di righe e totali prima/dopo ogni passaggio e conto le chiavi senza match; definisco revenue e periodo, poi confronto actual con forecast usando varianza = actual−forecast e attainment = actual/forecast solo se forecast non è zero. Il +25% può derivare da un join many-to-many o dal confronto fra periodi diversi. Solo dopo il controllo formulo un insight e un'azione manageriale proporzionata.

Model answer · English

Standardize keys, dates, currency and price units; handle duplicates and returns; ensure joins do not multiply sales. Reconcile row counts and totals at each step, inspect unmatched keys, define revenue and period, and calculate variance and attainment only with valid denominators. The reported gain may be a join or period artifact.

Perché è plausibile

È la missione pratica di Lesson 4 tradotta in un controllo concreto con feedback.

Errore frequente

Accettare il numero generato da una query o da AI senza riconciliazione dei join.

Fonte e localizzatore

canvas-133640__BigDataBsnsRizzi2026Lesson4.pdf · pp.24–25

Checklist di autovalutazione

- ▫ Chiavi
- ▫ Unità/periodi
- ▫ Duplicati/resi
- ▫ Row count
- ▫ Totali
- ▫ Denominatore

15 · Ragionamento critico

A team says a recommendation model proves its messages cause customers to buy more. What are the three different claims hidden in that sentence?

Prima prova a rispondere in inglese, poi confronta il modello.

Risposta modello · italiano

La frase mescola tre affermazioni: misurare una preferenza osservata, prevedere il comportamento futuro e dimostrare che il messaggio lo cambia. Click e acquisti sono proxy incompleti; la previsione richiede casi fuori campione; l'effetto causale richiede un confronto credibile, per esempio gruppi randomizzati A/B con stessa metrica e finestra. L'impatto incrementale stimato è tasso outcome B meno tasso outcome A, con incertezza: chi compra dopo un messaggio poteva comprare comunque. Inoltre la raccomandazione cambia ciò che il cliente vede: raccomanda → espone → osserva → aggiorna; i click riflettono sia preferenze sia opportunità create dal sistema. Per non rinforzare solo i prodotti già esposti monitoro esposizione, diversità e soddisfazione nel tempo, e distinguo conversioni incrementali da totali.

Model answer · English

The claim mixes observed preference, prediction and causal impact. Clicks are imperfect proxies; prediction needs unseen cases; impact needs a credible comparison, such as randomized A/B groups measured with the same outcome window. Estimated incremental effect is outcome rate B minus outcome rate A, with uncertainty: a buyer might have purchased anyway. Recommendations also create feedback loops—recommend, expose, observe, update—so clicks reflect both preferences and the opportunities the system offered. Track exposure, diversity and long-term satisfaction as well as incremental conversions.

Perché è plausibile

Lesson 4 distingue misurazione/predizione/causalità e illustra feedback loop delle raccomandazioni e A/B test.

Errore frequente

Confondere click, predizione e causalità oppure trattare i comportamenti osservati come preferenze non influenzate dal ranking.

Fonte e localizzatore

canvas-133640__BigDataBsnsRizzi2026Lesson4.pdf · Lesson 4 pp.33,37–38

Checklist di autovalutazione

- ☐ Proxy
- ☐ Predizione fuori campione
- ☐ A/B e impatto incrementale
- ☐ Feedback loop/esposizione
- ☐ Diversità e lungo termine

16 · Risposta breve

Why is a model or dashboard not 'finished' at deployment? Propose a monitoring plan for one business use case.

Prima prova a rispondere in inglese, poi confronta il modello.

Risposta modello · italiano

Il ciclo didattico della Lesson 4 unisce quattro capacità: prediction stima cosa accadrà, classification assegna una categoria, personalization ordina ciò che è rilevante per l'individuo, automation esegue o instrada un'azione. Poi misura l'esito e impara; nessuna capacità elimina governance o responsabilità. Per prevedere i no-show di un centro fitness monitoro qualità del collegamento prenotazione–ingresso, errore per fascia oraria, capienza, clienti respinti, reclami e privacy rispetto a una baseline. Se i rifiuti aumentano o cala la qualità del dato, sospendo l'overbooking e rivedo modello e workflow. Come nel caso del mutuo in Lesson 4, decisioni ad alto impatto o difficili da annullare richiedono spiegazione e controllo umano; deployment è l'inizio della verifica del valore, non la sua prova.

Model answer · English

Lesson 4 links four capabilities in a governed cycle: prediction estimates outcomes, classification assigns categories, personalization ranks individual relevance, and automation routes or executes actions; then measure and learn. For a gym no-show model, track booking-to-entry matching, error by time slot, capacity, refused customers, complaints and privacy against a baseline. Stop overbooking and review the workflow if data quality or customer outcomes fail. As the mortgage case shows, high-impact or hard-to-reverse decisions need explanation and human oversight. Deployment does not prove value.

Perché è plausibile

Week 1 richiede monitoraggio; Lesson 4 visualizza il ciclo delle quattro capacità e l'automazione supervisionata del caso mutuo.

Errore frequente

Presentare deploy o automazione come prova di valore e ignorare supervisione umana nelle decisioni ad alto impatto.

Fonte e localizzatore

2026-09-25__big-data-week-1-rizzi-aggiornato.pdf; canvas-133640__BigDataBsnsRizzi2026Lesson4.pdf · Week 1 pp.60–61; Lesson 4 pp.31–32

Checklist di autovalutazione

- ▫ Quattro capacità
- ▫ Metriche dati/modello/business
- ▫ Baseline e soglia stop
- ▫ Misura e apprendimento
- ▫ Supervisione umana