Provenienza: slide Canvas Week 4 Lesson 4 firmate Luca Rizzi 2026, 42 pagine, e ZIP del laboratorio. Collegamento alla giornata del 13/10 confermato da Canvas/calendario nel workflow, ma qui non è documentato il parlato delle due sessioni. Questo fascicolo copre le fonti scritte, non pretende di ricostruire parole del docente. Le spiegazioni, i calcoli e gli esercizi aggiunti sono esplicitamente didattici. [Slide PDF](../../../Materiale/canvas-133640__BigDataBsnsRizzi2026Lesson4.pdf) · [ZIP laboratorio](../../../Materiale/canvas-133641__Databricks_Mixed_Formats_Lab_Data.zip).

# Big Data & AI in Business — Lesson 4: Data Lake, formati e decisioni basate sui dati

Stato della fonte: spiegazione ricavata dalle 42 slide firmate «Luca Rizzi 2026» e dal pacchetto ZIP del laboratorio associato. Canvas Week 4 e calendario collegano il materiale alla giornata del 13 ottobre 2026, con due sessioni; non sono stati ascoltati audio né letti appunti orali, quindi il contenuto non è attribuito al parlato delle sessioni. I numeri degli esempi nelle slide sono illustrativi, salvo i record del file ZIP letti direttamente. I riferimenti p. indicano la pagina del PDF sorgente.

## 1. Che cosa risolve un Data Lake (p. 2–5)

Un Data Lake è un deposito che accoglie dati strutturati (per esempio una tabella di vendite), semi-strutturati (JSON o XML) e non strutturati (testi, immagini, log), spesso mantenendo il formato originale quando entrano. Pensa a un'azienda che riceve vendite dal sito, dati di magazzino, recensioni e registrazioni di assistenza: conservarli prima di aver fissato un unico schema permette usi analitici futuri non ancora previsti. «Native format» non significa però «nessuna preparazione»: per produrre un numero affidabile occorrono identità, date, unità, qualità e significato coerenti. La slide 3 parla di assenza di limiti fissi di dimensione; è una semplificazione, perché il limite effettivo dipende da tecnologia, costi e governo del sistema.

La distinzione didattica è schema-on-read: i dati possono entrare prima che ogni campo sia modellato per un report; lo schema necessario viene definito quando li si usa. Il data warehouse tradizionale tende a servire dati già modellati per analisi note. I due ambienti possono convivere (p. 12–13). La slide 4 contrappone architettura «flat» del lake a file/cartelle del warehouse: non è una regola universale; i sistemi reali hanno comunque percorsi, cataloghi, partizioni, tabelle e controlli. Ogni oggetto dovrebbe avere identificatore e metadata (provenienza, formato, periodo, owner, sensibilità, significato), altrimenti il deposito diventa difficile da trovare e fidarsi.

Le slide 4–5 propongono accesso più ampio ai dati, elasticità, meno silos e possibili usi di machine learning. Questi sono obiettivi condizionati, non conseguenze automatiche. Aumentare il volume non migliora necessariamente analisi o qualità: dati duplicati o non rappresentativi possono peggiorarle. Anche «visione a 360° del cliente» richiede collegare correttamente le identità e rispettare gli accessi. Esempio esplicativo ipotetico: un retailer unisce scontrini e web analytics nel lake; prima di decidere il budget campagne deve distinguere visitatori anonimi da clienti identificati e rimuovere conteggi doppi.

## 2. Dalla sorgente alla decisione: architettura e controlli (p. 6–14)

Il diagramma di p. 6 mostra il flusso sources → ingestion → storage → distillation → processing → insights → action, con unified operations sopra gli strati. Le sorgenti possono arrivare in batch (grandi carichi periodici), micro-batch (piccoli gruppi ravvicinati) o real time (flusso continuo). Non tutto deve essere in tempo reale: serve scegliere latenza e costo in base alla decisione. Un report mensile non richiede la stessa architettura di un allarme frode.

1. Ingestion tier acquisisce file o flussi da database, webserver, email, IoT, FTP (p. 7, 9). Qui si registra l'origine e si impedisce che un secondo caricamento dello stesso file raddoppi i dati.
2. Storage tier conserva i dati accessibili. La slide usa HDFS come esempio di storage di dati strutturati e non; HDFS è una tecnologia possibile, non la definizione di Data Lake. In altri sistemi lo storage può essere diverso. «Scalabile» significa poter crescere mantenendo costi e tempi gestibili, non una capacità infinita.

3. Distillation tier pulisce, seleziona e struttura i dati per l'analisi. Per esempio, converte una data testuale in una vera data e standardizza IT/Italy secondo una regola documentata. Il grezzo resta tracciabile.
4. Processing tier esegue query e algoritmi: batch per aggregati, interattivo per esplorare, vicino al tempo reale per decisioni rapide. Il diagramma cita database MPP (massively parallel processing) e motori in memoria come opzioni tecniche, non passaggi obbligatori.
5. Insights tier rende i risultati interrogabili con SQL, NoSQL o strumenti di analisi; action è la decisione o il processo che usa il risultato. Un grafico non è di per sé un'azione: serve una domanda aziendale e un responsabile.
6. Unified operations applica monitoraggio, policy, gestione workflow e audit trasversalmente. La slide 7 parla anche di «proficiency management», termine non spiegato: non lo tratto come componente tecnica definita.

Il cerchio di p. 8 e il testo di p. 9–11 aggiungono dimensioni indispensabili: ingestion, storage, governance, security, quality, discovery, auditing, lineage, exploration e collaborazione. Governance decide disponibilità, usabilità, responsabilità e regole; security applica autenticazione (chi sei), autorizzazione (cosa puoi fare), protezione dei dati e rendicontazione degli accessi. Data quality controlla completezza, accuratezza, coerenza e duplicati rispetto allo scopo. Discovery consente di trovare e capire dataset tramite cataloghi/tag. Auditing documenta chi ha cambiato cosa e quando. Lineage ricostruisce il percorso di una metrica dalle sorgenti alla dashboard: se la revenue è errata, consente di risalire al record, alla trasformazione e al report. Exploration verifica se il dataset è adatto prima di costruire un'analisi.

Le quattro fasi di maturità delle p. 12–13 sono una progressione didattica, non una scala di certificazione: (1) acquisire dati su scala, (2) sviluppare capacità di trasformazione e analisi, (3) usare insieme enterprise data warehouse (EDW) e Data Lake e diffondere gli insight, (4) integrare governance, lifecycle e metadata a livello aziendale. Le buone pratiche di p. 14 chiedono supporto ai formati nativi, componenti modulari e API, funzioni indipendenti per ingestione/qualità/visualizzazione, adattamento al settore e ingresso rapido di nuove sorgenti. «Guidato da ciò che è disponibile» va letto insieme alla domanda aziendale e ai controlli: accumulare dati disponibili senza scopo o diritti d'uso non crea valore.

Teamwork (p. 8) significa rendere collaborativo il lavoro sui dati: chi produce un campo deve spiegarne significato e limiti, chi lo trasforma documenta le regole, chi decide verifica che la metrica risponda alla domanda. Esempio didattico ipotetico: marketing chiama cliente chiunque visiti il sito, finance solo chi ha pagato. Un join tecnicamente riuscito non rende equivalenti le due definizioni. I due team concordano una definizione, assegnano un responsabile e conservano la versione usata nel report. Domanda: basta dare a tutti accesso al Lake? No: accesso senza significati condivisi e responsabilità può diffondere lo stesso errore a più persone.

Applicazione didattica delle fasi di maturità (p. 12–13). Immagina un retailer che salva tutti i file ma non sa ritrovare il dataset del report: ha capacità di acquisizione, non prova una gestione matura. Il passo utile è catalogare e trasformare un dataset verificabile, poi collegare Lake e warehouse alle decisioni effettive. Lifecycle significa seguire il dato da acquisizione a uso, aggiornamento, conservazione e ritiro secondo le regole applicabili; serve sapere quali report dipendono da una tabella prima di cambiarla. Nello stadio più integrato metadata, governance e lifecycle attraversano i reparti. Non contare quanti software sono installati: chiedi quale controllo manca nel percorso concreto. Prova: un nuovo catalogo, senza owner o regola di aggiornamento, dimostra lo stadio 4? No: è uno strumento; servono responsabilità applicate, versioni e controlli osservabili.

Componenti modulari e API (p. 14), spiegazione aggiunta. Modulare significa separare compiti con interfacce definite; una API è un contratto con cui un componente richiede o invia dati a un altro. Un reparto può cambiare il motore di visualizzazione senza riscrivere l'ingestione se campi, tipi, versioni, accessi ed errori dell'interfaccia sono concordati. Nel retailer ipotetico una nuova sorgente consegna country come testo: prima di integrarla verifica significato del campo, frequenza, autorizzazioni e comportamento quando il valore manca. Adattamento al settore significa aggiungere controlli pertinenti allo scopo, non un'etichetta sul software. Domanda: perché un nuovo connettore non basta? Perché velocizza l'ingresso ma non garantisce compatibilità semantica, diritti d'uso o qualità. Una API mal definita sposta il problema fra componenti invece di risolverlo.

Compatibilità con l'enterprise data management (ultimo punto di p. 14): il nuovo Lake deve collegarsi a catalogo, definizioni, gestione degli accessi e processi di qualità già adottati dall'impresa. Un catalogo parallelo che definisce revenue in modo diverso crea due verità concorrenti, anche se entrambe le query funzionano. Esempio ipotetico:

prima di importare fatture dal warehouse, riusa la definizione aziendale di ricavo netto e registra la trasformazione nel lineage; controlla che lo stesso mese dia lo stesso totale, oppure spiega la differenza. L'adattamento al settore modifica i controlli: un catalogo pubblico di prodotti e dati personali di richieste finanziarie non hanno la stessa platea d'accesso o necessità di dettaglio. Definisci scopo e sensibilità, limita chi vede quali campi e verifica il processo applicabile con il responsabile. Prova: copiare tutte le policy senza confrontarle con la nuova sorgente è sufficiente? No: compatibilità richiede verificare significati, accessi e flussi effettivi, non soltanto riusare nomi.

## 3. Quattro formati, quattro priorità (p. 15–23)

Le slide usano tre stream musicali con track_id 101/102/103, artisti Nova/Echo/Nova, paesi IT/BE/IT e 1200/980/1430 stream (p. 17). È lo stesso contenuto logico rappresentato in quattro modi. Una tabella di tre righe serve a vedere le differenze di struttura, tipo e accesso; non misura prestazioni reali.

| Formato | Come rappresenta i dati | Quando conviene | Attenzione |
|---|---|---|---|
| CSV (p. 18) | Riga di intestazione + righe con valori separati da virgole. | Tabelle piatte, scambio semplice ed editing umano. | Tipi impliciti: 101 potrebbe essere testo o numero; virgolette, virgole dentro i valori, encoding e celle vuote vanno gestiti. |
| XML (p. 19) | Albero di elementi/tag, attributi e gerarchie. | Documenti annidati e contratti con validazione formale. | Verbosità, namespace e schema richiedono parsing corretto. |
| JSON (p. 20) | Oggetti chiave-valore e array; valori tipizzati come numero, testo, booleano, null. | API, log/eventi e dati annidati. | Una struttura flessibile richiede validazione di sintassi, tipi e campi attesi; la ripetizione dei nomi delle chiavi in molti oggetti occupa spazio. |
| Parquet (p. 21) | File binario a colonne, con tipi e compressione. | Analisi di grandi tabelle quando si leggono poche colonne e molti record. | Non è comodo da modificare a mano; occorre software compatibile. La velocità dipende da workload, layout e dimensione. |

Row-oriented vs column-oriented: se una dashboard legge solo country e streams di milioni di righe, Parquet può evitare di leggere altre colonne e comprimere valori simili; se una persona deve correggere tre righe, CSV è più immediato. «Parquet è più veloce» senza specificare query e scala sarebbe un'affermazione eccessiva. Le p. 22–23 non indicano un vincitore assoluto: chiedono se i dati sono piatti, se gli esseri umani devono editarli e se il carico è analitico. Percorso comune della slide: acquisire testo → pulire/standardizzare → pubblicare un formato analitico come Parquet o Delta. Delta è menzionato soltanto, non spiegato nelle slide: non va scambiato per uno dei quattro formati confrontati.

Controllo JSON svolto (p. 20, spiegazione aggiunta): due oggetti scritti come {"track_id":101}, {"track_id":102} non formano un unico documento JSON. La forma [{"track_id":101}, {"track_id":102}] è un array valido di due oggetti. Il parser verifica la sintassi; dopo occorre ancora controllare campi, tipi e significato. Prova: se il parser accetta track_id come testo, dimostra che il join con un identificatore numerico funzioni correttamente? No: validità sintattica e compatibilità dei dati sono controlli diversi. Esempio ridotto ipotetico, non sostituzione dell'originale.

## 4. Laboratorio Databricks: costruire una vista attendibile (p. 24–25; ZIP allegato)

La missione è creare tabelle da customers.csv, products.xml, sales.json, forecast.parquet, uniformare identificatori, date, regioni, quantità e prezzi, poi unire vendite/clienti/prodotti e confrontare ricavo effettivo e previsto per mese × regione. La slide propone di far generare logica tramite prompt; il controllo umano è obbligatorio: righe in ingresso/uscita, chiavi mancanti, duplicati e totali. Una dashboard richiesta dovrebbe mostrare KPI, trend, confronto regioni e filtri, ma nessun dashboard finito è nel PDF.

Nel file ZIP letto direttamente, customers.csv ha 4 clienti: Aurora Records (IT/South), North Star Music (BE/North), Blue Note Digital (FR/West), Pulse Audio (DE/Central). products.xml elenca Standard P01 a 9,99, Premium P02 a 14,99 e Live Pack P03 a 44,99; P03 compare due volte identico. sales.json ha 9 righe fisiche per 8 sale_id distinti: S008 è ripetuta identica. La quantità 1200 della prima vendita P02 è molto più alta delle altre quantità nel piccolo esempio, quindi va segnalata come valore da controllare, non cancellata automaticamente. forecast.parquet contiene le colonne month, region, forecast_revenue (testo, testo, float64). La lettura locale del file restituisce 16 righe, una per ogni coppia dei quattro mesi gennaio–aprile 2026 e delle quattro regioni; nessun valore nullo o coppia duplicata. Il forecast totale è 30.250,00 unità monetarie, ma non si confronta con un sottoinsieme delle vendite. Per marzo × North il forecast è 1.950,00. Sono valori del dataset didattico, non osservazioni aziendali reali; la valuta non è specificata. La lettura è stata controllata su schema, dizionari, conteggi e confini delle pagine del file; non dimostra che la previsione sia accurata.

Procedura riproducibile per il controllo: contare righe e chiavi uniche di ciascuna sorgente; registrare le due duplicazioni; definire la regola di deduplica (per sale_id, dopo verificare che le righe siano davvero uguali; per product_id, dopo verificare che prezzo/categoria coincidano); eseguire join mantenendo visibili gli unmatched; calcolare revenue = quantity × unit_price per ogni riga valida; raggruppare per month(date) e region(customer_id); unire con forecast sulla coppia mese-regione; controllare che ogni coppia abbia al massimo un forecast e che le somme prima/dopo l'aggregazione tornino. In presenza di duplicati, un join diretto senza deduplica moltiplicherebbe le righe: P03 duplicato duplica le vendite P03; S008 duplicata conta due volte la stessa vendita. Non attribuire il fenomeno a un bug di Databricks: è una proprietà dei dati e della logica di join.

Esempio svolto sui record veri dello ZIP, con regola dichiarata: poiché S008 e P03 sono copie identiche, ne tengo una occorrenza ciascuno. Per S001 il prodotto P02 costa 14,99 e la quantità è 1200: 1200 × 14,99 = 17.988,00 unità monetarie, gruppo 2026-01 × South. S002 vale 180 × 9,99 = 1.798,20 nel gruppo 2026-01 × North. Ripetendo per le otto vendite uniche, l'actual totale condizionato a questa regola è 35.677,80 unità monetarie. Il gruppo 2026-04 × West vale 2.197,80 da una sola S008. Un join diretto che mantiene entrambe le righe P03 e S008 produrrebbe 45.973,80, cioè 10.296,00 in più: 3.599,20 da S003 duplicata nel join, 4.499,00 da S006 e 2.197,80 da S008. È una verifica di integrità, non una misura aziendale reale; valuta, quantità eccezionale di S001 e regola di deduplica devono essere confermate prima di usarla come KPI.

Formule da saper spiegare: revenue_i = quantity_i × unit_price_i (unità monetaria non specificata dal file: scrivere «unità monetarie» finché non è confermata la valuta); actual_(mese,regione) = somma delle revenue_i nella coppia; variance = actual − forecast (positivo = oltre il piano, se forecast è positivo); attainment % = 100 × actual / forecast. Se forecast = 0, l'attainment non è definito; occorre un'etichetta, non dividere per zero. Per il variance %, se richiesto, specificare prima una definizione: 100 × (actual − forecast) / forecast quando forecast ≠ 0. Esempio esplicitamente ipotetico: actual 120 e forecast 100 danno variance +20 e attainment 120%; questi numeri non provengono dal ZIP.

## 5. Quattro capacità AI: la domanda guida il metodo (p. 26–32)

La p. 27 raccoglie vendite, ricerche, wishlist, stock, tempi fornitori, promozioni, eventi e social di un negozio giocattoli. Gli stessi dati possono rispondere a domande diverse: prediction stima una quantità/probabilità futura (quanti giocattoli saranno venduti); classification assegna una categoria (transazione sospetta o legittima); personalization ordina opzioni per un individuo (quale gioco mostrargli); automation fa eseguire o instradare un'azione (riordinare stock). I risultati sono rispettivamente stima/probabilità, etichetta, ranking e azione. Servono obiettivi, dati e metriche differenti; un unico dataset non giustifica qualunque uso senza qualità e autorizzazione.

La previsione di consegna (p. 28) combina disponibilità/ora/opzione dell'ordine, magazzino/carico, capacità e storico del vettore, distanza/traffico/meteo, giorno/festività. Il modello usa storico e aggiornamenti per un intervallo e una probabilità: la slide offre un output illustrativo, «domani 14–17» e «85% entro due giorni», non una promessa o benchmark. Eventi nuovi portano a ricalcolare e avvisare il cliente. Le metriche suggerite sono errore assoluto medio (MAE: media di |tempo reale − tempo previsto|, nella stessa unità di tempo), quota di arrivi dentro la finestra, ritardo quando si arriva tardi e stabilità delle stime nel tempo. Un MAE basso non garantisce che gli intervalli probabilistici siano calibrati; bisogna valutare entrambi.

La classificazione antifrode (p. 29) usa segnali come importo, categoria negozio, ora/luogo, dispositivo/rete, abitudini, frequenza, distanza, storico e tentativi di autenticazione. Produce uno score e una classe di rischio; la slide propone approvazione a rischio basso, verifica aggiuntiva a medio e revisione umana ad alto. Queste sono decisioni di processo illustrate, non regole bancarie universali. La matrice di confusione confronta verità e decisione: TP frode segnalata, FN frode lasciata passare, FP pagamento legittimo segnalato, TN legittimo approvato. Qui un FP causa frizione, un FN possibile perdita. Se le frodi sono rare, classificare tutto «legittimo» può dare accuratezza alta ma recall frodi nullo. Metriche: precision = TP/(TP+FP); recall = TP/(TP+FN); false positive rate = FP/(FP+TN); F1 = 2 × precision × recall/(precision+recall), quando i denominatori sono definiti. La soglia va scelta in base ai costi dei due errori e alla capacità di revisione, non soltanto all'accuracy.

La personalizzazione musicale (p. 30) pesa ascolti completi, replay, skip, like, playlist, ricerche e contesto. Content-based confronta caratteristiche dei brani; collaborative filtering usa schemi di utenti simili; context-aware usa momento/dispositivo/sessione; hybrid combina i segnali. Due persone che cercano «focus music» possono ricevere ordinamenti diversi. Il ranking dovrebbe bilanciare rilevanza, scoperta e diversità, non soltanto click. Completion, skip, replay, salvataggi, scoperta, retention sono metriche distinte; nessuna da sola certifica benessere o gradimento. Rischi: filter bubble, ripetizione, popularity bias e privacy. I nomi/brani dell'immagine sono esempi grafici, non tracce verificate.

Lettura dei segnali musicali (p. 30): completare un ascolto è un possibile segnale positivo, riascoltare può suggerire preferenza più forte, uno skip precoce può indicare scarso adattamento al contesto e inserire un brano in playlist può indicare interesse duraturo. Sono interpretazioni operative da verificare, non misure certe del gusto: autoplay, distrazioni, ascolto condiviso e obiettivo della sessione possono cambiare il significato. Per esempio ipotetico, saltare una canzone già apprezzata mentre si studia non dimostra che non piaccia più. Confronta più segnali nel contesto e controlla varietà e soddisfazione, invece di trasformare ogni click in una preferenza permanente.

L'automazione di una richiesta mutuo (p. 31) passa da domanda e verifica documenti a calcolo di sostenibilità e instradamento. La slide definisce debt-to-income ratio: pagamenti mensili del debito / reddito mensile lordo (se reddito > 0). Esempio ipotetico: rate 600 + 200 e reddito lordo 3200 danno 800/3200 = 25%; non basta da solo per decidere un mutuo. Gli esiti possibili comprendono eleggibile in linea di principio, documenti aggiuntivi, revisione specialistica o fuori dai criteri con spiegazione/appello. La previsione può stimare difficoltà di rimborso, la classificazione un livello di rischio e l'automazione instradare il caso. La slide distingue manuale, assistito, supervisionato e condizionale; per decisioni ad alto impatto richiede controllo umano. Reason codes, audit trail, fairness testing, protezione, monitoraggio del drift, override e appello sono controlli da progettare, non prova che un sistema concreto sia conforme a ogni normativa.

La p. 32 collega data → predict → classify → personalize → act → measure → learn. È uno schema di apprendimento governato, non l'obbligo di applicare tutte le capacità in sequenza a ogni processo. La governance attraversa ogni fase: qualità, spiegabilità, equità, privacy, controllo umano e monitoraggio. Più automatismo può essere ragionevole per azioni reversibili e a bassa conseguenza; decisioni difficili da invertire richiedono più supervisione. Il valore è misurare gli effetti reali dopo l'azione, non soltanto produrre uno score.

Livelli di automazione (p. 31), spiegati passo per passo. Manual: il sistema mostra i dati e la persona analizza e decide. Assisted: il sistema calcola o raccomanda, la persona esamina e decide. Supervised: un essere umano approva o cambia la proposta; la slide lo indica per decisioni di mutuo ad alta conseguenza. Conditional: i casi chiari seguono regole definite, le eccezioni passano a revisione. Il confine dipende da chi può autorizzare l'esito e quando interviene, non da quanto moderna sia l'interfaccia. Esempio ipotetico: controllare automaticamente che un documento sia presente non equivale ad approvare il prestito; reddito incoerente o dato mancante richiedono una via di revisione,

non un valore inventato.

Controlli dell'automazione (p. 31). Reason codes sono motivi comprensibili della proposta e indicazioni sul passo successivo; audit trail conserva dati usati, esiti e modifiche per ricostruire una decisione. Fairness testing confronta esiti ed errori fra gruppi pertinenti, senza presumere che escludere un campo sensibile elimini variabili proxy correlate. Manual override consente a un responsabile di cambiare l'esito; human appeal offre una contestazione effettiva. Data protection governa accesso e uso dei dati; model drift monitoring controlla se distribuzioni o relazioni cambiano dopo il rilascio. Sono compiti differenti: un log non corregge da solo una discriminazione, e una spiegazione non sostituisce l'appello. Prova: un sistema dà una motivazione ma nessuno può rivedere un errore; è sufficiente? No: manca il controllo umano dell'esito. La conformità normativa resta da verificare nel contesto concreto, non è certificata dalla presenza di questa lista.

Metodi e misure a confronto (p. 32), spiegazione aggiunta. Per prediction, una regressione stima una quantità da relazioni fra variabili; una time series usa l'ordine temporale; gradient boosting combina modelli successivi per correggere errori. La scelta richiede confronto su dati non usati per adattare il modello. Prediction error misura distanza fra stima e valore reale; calibration verifica se probabilità dichiarate corrispondono alle frequenze osservate: se molte previsioni indicano 80%, circa otto casi su dieci dovrebbero verificarsi in un gruppo comparabile. Un basso errore medio non dimostra calibrazione, né stabilità in condizioni nuove.

Per classification, logistic regression produce probabilità di classe, decision trees separano casi con regole successive e neural networks apprendono combinazioni di caratteristiche. Non sono tre garanzie di qualità crescente: contano dati, validazione, interpretabilità e costo. Precision, recall e F1 valutano aspetti diversi degli errori, come mostra l'esercizio 8.5. Per personalization, collaborative filtering usa comportamenti di utenti simili, content models confrontano attributi degli oggetti e ranking ordina le alternative. Engagement misura interazioni; diversity misura varietà delle proposte secondo una definizione dichiarata; satisfaction richiede un segnale di soddisfazione distinto dai soli click. Ottimizzare una misura può peggiorarne un'altra.

Per automation, rules e thresholds traducono condizioni e soglie in un'azione; orchestration coordina passi, servizi, tempi ed eccezioni. Le metriche proposte dalla slide sono time saved, exception rate e outcome quality. Tempo risparmiato = tempo di confronto meno tempo del nuovo processo, includendo controlli e recuperi; tasso di eccezioni = casi inviati fuori dal flusso ordinario / casi totali, con finestra e denominatore definiti; qualità dell'esito richiede una misura adatta allo scopo. Caso ipotetico: un processo passa da dieci a sei minuti per pratica, ma produce più errori da correggere. Quattro minuti nominali non dimostrano un miglioramento complessivo. Prova: zero eccezioni significa automazione perfetta? No: può significare che il sistema non riconosce i casi anomali. Confronta tempo, eccezioni rilevate e qualità su casi controllati.

## 6. Correlazione, previsione e impatto causale (p. 33–38)

Le p. 33–34 chiedono di separare popolarità (classifica uguale per molti sulla base di ordini/click aggregati) da personalizzazione (rilevanza per una persona, tenuto conto di preferenze e contesto). Pizza, laptop e feed illustrano la differenza: il bestseller può essere inadatto a chi cerca un prezzo basso, dieta particolare o contenuti culinari. Il comportamento passato è un indizio, non identità permanente. La domanda di valutazione è «rilevanza per utente» oltre ai click totali.

La p. 35 distingue hindsight (spiegare ciò che si è già osservato) da prediction (stimare esiti ancora ignoti usando solo informazioni disponibili al momento della decisione). Data leakage avviene quando informazioni future o legate all'esito entrano nel training o nella valutazione e gonfiano la performance apparente. Esempi della slide: vendite effettive di domani per prevedere domanda di domani; sessione video già completata per prevedere se sarà guardata; ora di arrivo reale per prevedere ritardo all'ordine. Controllo: segnare il timestamp decisionale, separare training precedente e test successivo quando si prevede il futuro, adattare preprocessing solo al training e valutare su dati mai visti. Anche così, un buon risultato storico non prova automaticamente un guadagno operativo.

Le p. 36 e 29 chiariscono false positive e false negative: «positivo» vuol dire presenza della condizione bersaglio, non «buono». Nel controllo alimentare: FP scartare cibo sano, FN accettare cibo guasto. Nella moderazione: FP rimuovere contenuto lecito, FN lasciare una violazione. Nei pagamenti: FP rifiutare acquisto lecito, FN approvare frode.

Abbassare la soglia di classe positiva, a modello fisso, in genere trova più veri positivi ma genera più falsi allarmi; occorre conoscere il costo di ogni errore.

La p. 37 mostra un feedback loop: il sistema raccomanda → le persone vedono → reagiscono → il modello usa quella reazione. Una pizza messa in alto riceve più ordini anche perché è stata esposta; nuovi prodotti poco mostrati hanno pochi click e quindi pochi dati. Un feed può riproporre contenuti simili restringendo la scelta. Non si può leggere ogni click come preferenza «pura» senza considerare le opportunità create dal sistema. Rimedi illustrati: esplorare alcune opzioni meno esposte, confrontare risposte rispetto all'esposizione e monitorare diversità/soddisfazione nel tempo.

La p. 38 distingue predire chi comprerà da misurare chi compra grazie all'intervento. In un test A/B, utenti eleggibili vengono assegnati casualmente al gruppo A (versione attuale) e B (nuova). Si misura la stessa metrica nella stessa finestra. La differenza osservata stima l'impatto medio dell'intervento se randomizzazione, esposizione e misurazione sono valide; per un singolo utente non si osservano contemporaneamente i due esiti possibili. Formula: impatto incrementale stimato = tasso di outcome in B − tasso in A, in punti percentuali se entrambi sono percentuali. Esempio ipotetico: 12 acquisti su 100 assegnati a B (12%) e 10 su 100 ad A (10%) producono +2 punti percentuali, non +2% relativo; con campioni così piccoli la differenza può essere casuale. Definire metrica, dimensione campione e durata prima di guardare i risultati; riportare incertezza. Per lo sconto pizza serve profitto per cliente assegnato, non soltanto ordini; per feed, soddisfazione ed effetti collaterali; per shopping, acquisti aggiuntivi per visitatore assegnato.

## 7. Casi di errore e preparazione alla verifica (p. 39–42)

La p. 39 usa una citazione motivazionale sul fallire e imparare; non fornisce una procedura di validazione. La p. 40 presenta tre casi riportati dalle slide. Per Zillow Offers riporta un write-down Q3 2021 di 304 milioni di dollari e lo lega a previsioni/automazione; per Amazon descrive un progetto sperimentale di ranking CV, riportato nel 2018 e abbandonato, con rischio di apprendere discriminazioni storiche. I dettagli di questi due casi restano non verificati qui su fonti originali, quindi sono esempi della slide, non prova indipendente. Il caso eBay ha invece un riscontro primario: Blake, Nosko e Tadelis, Consumer Heterogeneity and Paid Search Effectiveness: A Large Scale Field Experiment (NBER Working Paper 20171, maggio 2014), riporta esperimenti sul campo in cui i rendimenti della paid search eBay sono inferiori alle stime osservazionali; gli annunci su parole chiave del marchio non mostrano un beneficio misurabile nel breve periodo, mentre annunci su parole non di marca influenzano soprattutto utenti nuovi/occasionali e i clienti frequenti, poco influenzati, dominano la spesa. I rendimenti medi risultano negativi nel contesto studiato. Non generalizzare a tutta la pubblicità o ad altre aziende: campagna, clienti, periodo e metrica possono cambiare l'effetto. Il punto didattico è misurare incrementalità con un confronto credibile, non dedurla da click/acquisti osservati. La p. 41 annuncia un warm-up assessment «AI & Big Data fundamentals», 15 domande, 4 scelte e 3 livelli; le domande non sono nel PDF. La p. 42 è chiusura.

Meccanismi dei casi di p. 40, attribuiti alle slide. Per Zillow, il materiale collega volatilità inattesa dei prezzi, vincoli di capacità e difficoltà operative a previsioni e impegni di acquisto costosi: una previsione può essere ragionevole in media ma produrre esposizione finanziaria eccessiva quando l'impresa compra beni prima di rivenderli. La lezione è confrontare intervalli d'incertezza, capacità operativa e perdita potenziale, oltre all'errore medio. Per Amazon recruiting, la slide descrive candidature storiche prevalentemente maschili e indicatori associati alle donne penalizzati: apprendere un pattern passato può riprodurre disparità invece di misurare capacità lavorative. Verifica rappresentatività dei dati, variabili proxy e risultati per gruppo. I dettagli storici di entrambi rimangono riportati dalla slide, non confermati qui da fonti primarie. Per eBay, la lezione sostenuta dal paper citato è che utenti già propensi ad acquistare possono far apparire efficaci annunci che non aggiungono acquisti: il confronto sperimentale separa propensione iniziale ed effetto dell'annuncio nel contesto studiato. Prova: un modello più accurato risolve tutti e tre i problemi? No: servono anche limiti d'esposizione, controllo delle disparità e una misura causale dell'intervento, rispettivamente.

### Una verifica di comprensione ad alto rendimento

Prendi il caso del laboratorio e disegna, senza software, il percorso file grezzi → deduplica e tipi → join → ricavo per mese/regione → forecast → variance → dashboard. Accanto a ogni freccia scrivi un controllo (per esempio chiave univoca, righe unmatched, totale prima/dopo). Poi chiediti: «Sto descrivendo il passato, prevedendo il futuro o misurando l'effetto di una nostra azione?» Se non sai rispondere, la metrica finale rischia di essere interpretata male.

## 8. Impara applicando: esercizi con feedback ragionato

Questa parte serve a usare i concetti, non a ripetere nomi. Ogni scenario nuovo è ipotetico; i numeri delle vendite nell'esercizio 3 sono invece letti dallo ZIP. Prova prima a rispondere senza guardare il feedback.

### 8.1 Data Lake: capire il flusso e il punto di fiducia

Situazione svolta. Un negozio ha ordini CSV, click web JSON e foto di resi. Vuole capire se i resi aumentano dopo un cambio fornitore. Acquisisce i tre flussi con data e fonte; conserva i grezzi; cataloga il fornitore e collega ordine-reso tramite chiave valida; controlla i resi senza ordine e i duplicati; soltanto dopo confronta periodi e fornitori. Il Lake rende possibili usi diversi, ma non risolve da solo la compatibilità degli identificatori o la qualità del dato. Se le foto non sono necessarie per la domanda, non serve analizzarle.

Applica a un caso nuovo. Una catena di ristoranti riceve scontrini, recensioni testuali e temperatura dei frigoriferi. Quali due metadata registreresti per ogni flusso? Quale controllo faresti prima di collegare recensioni e scontrini?

Feedback. Risposta forte: per ogni flusso almeno origine/responsabile e timestamp con fuso orario; aggiungere schema, unità e regole di accesso. Prima del collegamento, verificare se esiste un identificatore cliente/ordine lecito e affidabile. Il solo fatto che due eventi avvengano nello stesso giorno non prova che siano della stessa persona. Se rispondi «metto tutto nel Lake e faccio una dashboard», manca il passaggio decisivo di identità, qualità e governance.

### 8.2 Formati: spiegare la scelta, non memorizzare una classifica

Situazione svolta. Una piccola tabella di prezzi da correggere manualmente si scambia facilmente in CSV; una API che invia ordini con array di prodotti si adatta a JSON; un contratto di messaggi con gerarchia e schema formale può usare XML; una query mensile che legge due colonne su milioni di transazioni può beneficiare di Parquet. La stessa organizzazione può avere tutti e quattro i formati nello stesso flusso.

Applica a un caso nuovo. Un'azienda riceve ogni secondo eventi JSON dagli utenti. Dopo un anno vuole analizzare solo country e watch_time su centinaia di milioni di eventi. Quale formato manterresti all'ingresso e quale useresti per l'analisi? Quale errore resta possibile anche se il formato di uscita è scelto bene?

Feedback. Una buona risposta conserva il JSON originale come fonte tracciabile e prepara una tabella analitica tipizzata, eventualmente in Parquet, con quelle colonne e partizioni adatte alle query. Restano possibili doppioni, codici paese incoerenti, unità di watch_time diverse o perdita della relazione con l'utente. «Parquet corregge i dati» è falso: organizza la lettura, non garantisce verità. Verifica anche schema e performance reali prima di promettere un guadagno.

### 8.3 Lab: una cifra giusta richiede una regola giusta

Situazione svolta sui dati veri. La vendita S003: quantità 80 di P03 a 44,99, cliente 1 in regione South, data febbraio 2026. Una sola riga S003 produce 80 × 44,99 = 3.599,20. Ma products.xml contiene due righe P03 identiche; un join non controllato produrrebbe due righe S003 e 7.198,40, pur essendoci una sola vendita. Il controllo «numero di sale_id distinti prima e dopo il join» intercetta il problema.

Applica a un caso nuovo dello stesso ZIP. Senza leggere il feedback, calcola il ricavo del gruppo 2026-03 × North dopo aver tenuto una sola P03. Poi spiega perché sarebbe scorretto sommare il forecast di tutte le regioni e confrontarlo soltanto con North.

Feedback. La sola S006 di North a marzo è 100 unità di P03: 100 × 44,99 = 4.499,00. Un confronto valido richiede stesso mese, stessa regione, stessa unità e stessa definizione di ricavo. Il totale forecast di tutte le regioni ha un

perimetro diverso e produce una variance senza significato. Nel file forecast la stessa coppia 2026-03 × North vale 1.950,00 unità monetarie. Con la regola di deduplica dichiarata: variance = 4.499,00 − 1.950,00 = +2.549,00; attainment = 100 × 4.499,00 / 1.950,00 ≈ 230,72%. Significa che il ricavo osservato nel dataset supera quel piano, non che la previsione sia migliorata o che la decisione abbia causato il risultato. Il totale forecast di 30.250,00 riguarda invece tutte le 16 coppie: prima di confrontare totali occorre definire come trattare coppie senza vendite e valori anomali.

## 8.4 Prediction, classification, personalization, automation: riconoscere l'output

Situazione svolta. «Quanti ordini arriveranno domani?» chiede una stima; «questo pagamento è sospetto?» una classe; «quale contenuto mostrare a questa persona?» un ranking; «devo aprire un ticket di revisione?» un'azione. L'azione può usare una previsione o classe, ma necessita una regola operativa e una persona responsabile.

Applica a un caso nuovo. Un ospedale vuole: (a) stimare la durata di attesa; (b) contrassegnare un referto per revisione; (c) ordinare informazioni utili al paziente; (d) inviare automaticamente un promemoria. Assegna una capacità e una metrica sensata a ciascuna, senza formulare decisioni cliniche automatiche.

Feedback. (a) prediction, errore sui minuti e calibrazione della finestra; (b) classification, recall/false positive rispetto alla condizione definita; (c) personalization, comprensione/utilità e diversità, non solo click; (d) automation, consegna corretta, eccezioni e possibilità di annullamento. Se usi l'accuracy per tutte e quattro, stai ignorando che cambiano output e costi degli errori. Lo scenario è didattico e non propone un sistema clinico reale.

## 8.5 Errori di classificazione: la soglia dipende dalle conseguenze

Situazione svolta ipotetica. Su 1.000 pagamenti, 20 sono frodi vere. Il modello segnala 30 pagamenti: 15 frodi vere e 15 pagamenti legittimi. Allora TP=15, FP=15, FN=5, TN=965. Precision = 15/30 = 50%; recall = 15/20 = 75%; false-positive rate = 15/980 ≈ 1,53%. L'accuracy è (15+965)/1000 = 98%, ma le cinque frodi perse e i quindici clienti disturbati rendono insufficiente giudicare con accuracy sola. Un sistema che approvasse tutto farebbe 98% accuracy, ma recall frodi 0%.

Applica a un caso nuovo. Una squadra abbassa la soglia e intercetta 18 frodi, ma segnala anche 60 pagamenti legittimi. È automaticamente meglio? Calcola recall e precision.

Feedback. TP=18, FN=2, FP=60, TN=920. Recall = 18/20 = 90%; precision = 18/78 ≈ 23,1%. Il recall migliora, la precision peggiora. Serve il costo economico della frode persa, il costo della frizione e la capacità di revisione per scegliere. «Più frodi trovate = sicuramente meglio» salta il trade-off. I numeri sono inventati per esercizio, non della slide.

## 8.6 Previsione contro causalità: chiedere la domanda giusta

Situazione svolta ipotetica. Un'app mostra una promozione ai clienti che il modello giudica «più propensi a comprare». Questi clienti poi comprano più degli altri. Questo non prova che la promozione funzioni: erano già più propensi. Per stimare l'effetto, assegna casualmente clienti eleggibili a promozione B o versione A, definisci acquisti o profitto per cliente assegnato e confronta le stesse finestre. Se B fa 12% e A 10%, la differenza osservata è +2 punti percentuali; non basta, da sola, a certificare un effetto non casuale.

Applica a un caso nuovo. Un social dice: «Il nuovo feed trattiene gli utenti, perché chi vede molti video resta più a lungo». Quali due problemi vedi e quale prova proporresti?

Feedback. Primo, selection/confounding: chi già ama i video potrebbe vederne di più e restare più a lungo. Secondo, feedback loop: il nuovo feed aumenta l'esposizione ai video, creando i click che usa come conferma. Prova: A/B randomizzato fra utenti eleggibili, stessa finestra, metriche di soddisfazione e retention, più controllo di diversità ed effetti negativi. Per testare previsione futura, separa nel tempo training e valutazione ed escludi dati conosciuti solo dopo la decisione. Un test A/B misura l'effetto della variante testata nel suo contesto; non prova che ogni futuro cambiamento avrà lo stesso effetto.

## 9. Definizioni operative

Questa tabella conserva nel fascicolo le stesse definizioni presenti nel file autonomo Definizioni/2026-10-13__definizioni.md. Le formule sono sviluppate nelle sezioni precedenti; ogni voce mantiene la pagina della slide e l'eventuale aggiunta didattica.

| Termine EN | Spiegazione in italiano e esempio | Fonte |
|---|---|---|
| Data Lake | Deposito di dati in diversi formati, anche grezzi, da catalogare e preparare per analisi successive. Esempio ipotetico: vendite, log web e recensioni di un retailer nello stesso ambiente governato. | p. 3–5 |
| Structured / semi-structured / unstructured data | Dati rispettivamente in schema tabellare; con struttura flessibile come JSON/XML; senza schema tabellare diretto come testo o immagini. La classificazione dipende anche da come il dato è trattato. | p. 3, 9 |
| Metadata | Informazioni che descrivono un oggetto dati: origine, formato, significato, periodo e regole d'uso. Senza metadata due colonne region possono sembrare uguali pur avendo significati diversi. | p. 4, 13 |
| Schema-on-read | Definizione della struttura utile quando si legge e prepara il dato per un uso, senza imporre un unico schema aziendale all'ingresso. Non elimina pulizia e validazione. | p. 5, 14; spiegazione Codex |
| Ingestion | Acquisizione di dati da sorgenti in batch, micro-batch o flusso continuo; va registrata provenienza e deduplica. | p. 6–7, 9 |
| HDFS | Hadoop Distributed File System: componente di storage distribuito citato nell'architettura della slide, non requisito di ogni Data Lake. | p. 6–7 |
| Distillation | Preparazione/strutturazione dei dati grezzi per renderli analizzabili. Esempio ipotetico: convertire stringhe di data e normalizzare codici paese. | p. 6–7 |
| Data governance | Regole e responsabilità per disponibilità, usabilità, sicurezza e integrità dei dati. | p. 9, 13 |
| Authentication / authorization | Verifica di chi accede / verifica di ciò che può fare. Sono controlli diversi. | p. 10 |
| Data quality | Idoneità del dato allo scopo, incluse accuratezza, completezza, coerenza e duplicati. «Più dati» non equivale a «dati migliori». | p. 10; criteri esemplificati da Codex |
| Data discovery | Ricerca e comprensione dei dati disponibili tramite catalogo, descrizioni e tag. | p. 10 |
| Data auditing | Registrazione e verifica delle modifiche, dei responsabili e dei momenti; aiuta controllo e conformità. | p. 11 |
| Data lineage | Tracciamento dell'origine e delle trasformazioni dal record al risultato finale. Esempio ipotetico: risalire da KPI ricavi al file vendite e alle regole di join. | p. 11 |
| CSV | Testo delimitato a righe e colonne, adatto a tabelle piatte e scambio, con tipi spesso impliciti. | p. 18 |
| XML | Formato testuale ad albero con tag, attributi e possibilità di validazione di schema. | p. 19 |
| JSON | Formato testuale di oggetti/array e tipi di valore, comune per API ed eventi. L'esempio di p. 20 richiede doppi apici standard e un array esterno per i tre oggetti separati da virgole. | p. 20 |
| Parquet | Formato binario a colonne con tipi e compressione, utile per letture analitiche selettive. | p. 21 |
| Prediction | Stima di un esito futuro o non ancora noto con informazioni disponibili al momento della decisione; può produrre valore o probabilità. | p. 27–28, 32, 35 |
| Classification | Assegnazione di una classe/etichetta, spesso da uno score e una soglia. | p. 27, 29, 32, 36 |
| Personalization | Ordinamento/scelta delle opzioni secondo la rilevanza stimata per una persona e un contesto; non coincide con popolarità. | p. 27, 30, 32, 34 |

| Termine EN | Spiegazione in italiano e esempio | Fonte |
|---|---|---|
| Automation | Instradamento o esecuzione di un'azione tramite regole e sistemi; per decisioni ad alto impatto occorrono controllo e responsabilità umani. | p. 27, 31–32 |
| MAE (mean absolute error) | Media degli errori assoluti \|vero − previsto\|; nell'esempio consegne si misura nella stessa unità di tempo. | p. 28; formula esplicitata da Codex |
| True positive / false positive / false negative / true negative | Rispetto alla classe bersaglio: correttamente segnalato / segnalato per errore / non segnalato per errore / correttamente escluso. Nella frode, un pagamento legittimo bloccato è FP. | p. 29, 36 |
| Precision | Fra i casi segnalati positivi, quota davvero positiva: TP/(TP+FP), se denominatore > 0. | p. 29, 36; formula esplicitata da Codex |
| Recall | Fra i casi realmente positivi, quota trovata: TP/(TP+FN), se denominatore > 0. | p. 29, 36; formula esplicitata da Codex |
| False-positive rate | Fra i casi realmente negativi, quota erroneamente segnalata: FP/(FP+TN). | p. 29; formula esplicitata da Codex |
| F1 score | Media armonica di precision e recall: 2PR/(P+R) se definita; non misura direttamente costo economico degli errori. | p. 29, 32; formula esplicitata da Codex |
| Debt-to-income ratio | Pagamenti mensili del debito divisi per reddito mensile lordo, se reddito > 0. Un solo fattore della valutazione del mutuo. | p. 31 |
| Data leakage | Uso improprio, nel training o nel test, di informazioni non disponibili al momento della previsione o legate al target, con prestazioni apparenti gonfiate. | p. 35 |
| Feedback loop | L'azione del sistema cambia ciò che gli utenti vedono e fanno; quei comportamenti diventano dati di training futuri. | p. 37 |
| A/B test | Confronto di due esperienze con assegnazione casuale degli utenti eleggibili, stessa metrica/finestra e controllo dell'incertezza. | p. 38 |
| Incremental impact | Differenza dell'esito dovuta all'intervento; in un A/B test la stima illustrata è tasso B − tasso A. | p. 38 |

### Definizioni per applicare architettura e automazione

| Termine EN | Spiegazione in italiano e esempio | Fonte |
|---|---|---|
| Teamwork | Collaborazione fra chi produce, trasforma e usa i dati, con significati e responsabilità condivisi. | p.8; esempio didattico §2 |
| Data lifecycle | Percorso da acquisizione a uso, aggiornamento, conservazione e ritiro del dato secondo regole applicabili. | p.13; spiegazione aggiunta |
| API / modularity | Interfaccia concordata fra componenti con compiti separati; campi, tipi, versioni ed errori devono restare compatibili. | p.14; spiegazione aggiunta |
| Manual / assisted / supervised / conditional | Quattro gradi: persona analizza/decide; sistema raccomanda e persona decide; persona approva/cambia; casi chiari automatici ed eccezioni revisionate. | p.31 |
| Reason codes / audit trail | Motivi comprensibili e passi successivi / registrazione dei dati, esiti e modifiche per ricostruire la decisione. | p.31 |
| Fairness testing / proxy | Confronto di esiti ed errori fra gruppi / variabile correlata che può riprodurre distinzioni anche senza un campo sensibile esplicito. | p.31; spiegazione aggiunta |
| Human appeal / manual override | Via per contestare un esito / possibilità di un responsabile di modificarlo. Motivazione e log da soli non li sostituiscono. | p.31 |
| Drift monitoring | Controllo dei cambiamenti nei dati e nelle relazioni dopo il rilascio del modello. | p.31 |
| Regression / time series / gradient boosting | Stima da relazioni fra variabili / uso dell'ordine temporale / combinazione successiva di modelli per correggere errori. | p.32; spiegazione aggiunta |
| Calibration | Coerenza fra probabilità dichiarate e frequenze osservate in gruppi comparabili; distinta dall'errore medio. | p.32; esempio ipotetico §5 |
| Logistic regression / decision tree / neural network | Metodi che stimano probabilità di classe, separano con regole successive o apprendono combinazioni di caratteristiche; nessun ordine garantito di qualità. | p.32; spiegazione aggiunta |
| Collaborative filtering / content model / ranking | Uso di utenti simili / confronto di attributi degli oggetti / ordinamento delle opzioni. | p.30–32 |
| Rules / thresholds / orchestration | Condizioni operative / soglie che attivano una classe o azione / coordinamento di passi, servizi ed eccezioni. | p.32; spiegazione aggiunta |
| Time saved / exception rate / outcome quality | Differenza di tempo col processo di confronto includendo recuperi / quota casi fuori flusso ordinario / misura dell'esito adatta allo scopo. | p.32; esempio ipotetico §5 |

## Note di verifica delle fonti

Queste note chiariscono limiti del materiale; non sono concetti da memorizzare per la lezione.

- La slide 20 contiene virgolette tipografiche e tre oggetti separati da virgole senza un array esterno. Per ottenere un unico documento JSON valido servono doppi apici standard e parentesi quadre attorno alla sequenza, quindi il controllo con un parser; correggere soltanto gli apici non basta. Una sequenza JSON Lines usa invece un oggetto valido per riga senza virgole fra le righe: è un formato di flusso distinto.
- Le descrizioni degli stadi 1 e 2 di maturità (slide 12) ripetono parti del testo; il claim della slide 13 secondo cui pochissime organizzazioni raggiungono lo stadio 4 non porta una quota o un periodo. La sequenza va letta come schema concettuale, non come statistica.
- Nel ZIP i duplicati S008 e P03 sono identici, ma una regola operativa di deduplica va comunque documentata; il ricavo actual di questo fascicolo dipende da quella scelta. La valuta non è specificata. I 16 valori forecast sono stati letti localmente con controlli strutturali e doppia rilettura del decoder limitato a questo file; manca un confronto con un secondo software indipendente. La quantità 1200 di S001 è un valore da verificare, non un errore dimostrato.

- Il dettaglio storico di Zillow e Amazon recruiting nella slide 40 non è stato qui riscontrato su fonti originali. Il working paper NBER 20171 (2014) supporta il caso eBay nel suo contesto, senza generalizzazione ad altre campagne.
- Il PDF non contiene le 15 domande annunciate nel warm-up della slide 41; non è disponibile una registrazione o trascrizione delle due sessioni per verificare cosa sia stato spiegato oralmente.