Big Data & AI in Business
Capire. Collegare. Scrivere.

Guida bilingue di preparazione · 18 ottobre 2026

Italiano con termini e definizioni inglesi + English study companion. Esempi svolti, ragionamenti e allenamento.

Data e formato del prossimo assessment non confermati. Le domande di questa guida sono esercizi originali, non tracce annunciate dal docente.

Il perimetro comprende le quattro settimane disponibili, con limiti delle registrazioni dichiarati nel testo. Nessuna attestazione di ascolto diretto integrale né di lettura di tutta la bibliografia generale.

Big Data & AI in Business — guida ragionata alle prime quattro settimane

Materiale di studio, 18 ottobre 2026. Copre i fascicoli corretti del 25 e 29 settembre, 6 e 13 ottobre e le slide Rizzi Lesson 1–4. Le prime tre date comprendono materiale di Luca Rizzi e Riccardo Campana; per il 13 ottobre sono disponibili slide e file di laboratorio, non audio/trascrizione della giornata. Gli esempi inventati sono indicati come tali. Nessuna data, forma o domanda di una futura verifica è dedotta da una slide di warm-up o da conversazioni registrate.

Quadro di valutazione verificato il 18/10 su Canvas dal task integratore: il modulo HFARM502 pesa 20% per due subcomponent in classe da 10% ciascuno e 80% per un blog di 3.200 parole. Il descriptor p.3 colloca i due touchpoint nelle settimane 3–6 e 6–10, con preavviso del tutor di una settimana, e elenca possibili forme (blog/riflessione/review da 400 parole, presentazione o viva da 10 minuti, seminario, dibattito). La prova da 20 domande a scelta multipla è espressamente limitata ai moduli Level 4; **non è un formato confermato per questo Level 5**. L'Assignment 3007 su Canvas mostra per il blog la consegna del 13 gennaio 2027 alle 16:00 e chiusura del 20 gennaio alle 16:00; questa informazione riguarda l'80% e non fissa il prossimo subcomponent. Questa guida è un tutor per comprendere e rispondere con parole proprie, non un elaborato da consegnare. La pagina Reading Materials offre anche libri e articoli generali: la loro presenza non equivale all'assegnazione integrale per la prossima prova.

I rimandi sono ai PDF nel corso H-FARM/BCE HQ 26:27/1^ Semestre/Big Data & AI in Business/Materiale/: **L1** = 2026-09-25__big-data-week-1-rizzi-aggiornato.pdf (61 pp.; la copia 23/09 ha 62 pp. e non è usata per la paginazione); **L2** = BigDataBsnsRizzi2026Lesson2.pdf (45 pp.); **L3** = BigDataBsnsRizzi2026Lesson3.pdf (55 pp.); **L4** = canvas-133640__BigDataBsnsRizzi2026Lesson4.pdf (42 pp.). **A25/A29/A06** sono gli appunti corretti delle rispettive date in Lezioni/<data>/pdf/; **E25/E29/E06/E13** le spiegazioni estese. Sono ricostruzioni controllate di testo e slide, non una nuova verifica acustica. Le pagine della slide non certificano che ogni frase sia stata pronunciata in aula.

1. La domanda centrale: quale decisione migliora?

English definition to practise: *“Business value from data is an improvement in an observable decision and outcome, compared with a credible baseline, after costs and risks.”* Non è una citazione del docente: è una formula per spiegare il corso in inglese.

Rizzi parte dal **why**: prima di scegliere un modello bisogna sapere quale problema aziendale meriti un intervento [A25 §1; E25 §1; L1 pp.5, 60]. Campana completa il percorso: raccolta, preparazione, analisi, distribuzione, uso e riuso dei dati [A25 §1, Campana 21–24′]. Se il risultato rimane su una dashboard che nessuno consulta, la catena si interrompe. Se il manager lo consulta ma non ha budget o autorità per agire, resta un'informazione interessante. Se agisce, serve misurare se la decisione è stata migliore della pratica precedente. **Precisione tecnica, adozione ed effetto aziendale sono tre prove differenti.**

Esempio **ipotetico**: un negozio vuole evitare scaffali vuoti senza aumentare troppo l'invenduto. “Prevedere le vendite” è un mezzo. La decisione è *quanto ordinare, quando e da chi*; l'esito è servizio al cliente, margine e costo delle scorte. Dati necessari: vendite, promozioni, stock disponibile, tempi dei fornitori. Una vendita zero durante uno stockout non è domanda zero: il cliente avrebbe potuto comprare ma non trovava il bene. Come baseline usa la regola attuale del responsabile. Il nuovo modello va testato

su settimane successive non usate per costruirlo. Il responsabile deve poter correggere un suggerimento e registrare perché. Alla fine confronti rotture di stock, invenduto e margine a parità di periodo e condizioni plausibili, evitando di attribuire automaticamente ogni cambiamento all'AI.

La sequenza nelle slide è **Frame** → **Acquire** → **Build** → **Adopt** → **Monitor** [L1 p.60]. *Frame* fissa decisione e misura; *Acquire* trova dati idonei e diritti d'uso; *Build* prepara, confronta una baseline e valida; *Adopt* inserisce il risultato nel flusso di lavoro; *Monitor* controlla esito, errori e cambiamenti dei dati. Usala come checklist decisionale, non come garanzia che ogni progetto AI funzioni. **Domanda di controllo:** se nessuno può agire prima che il danno accada, a cosa serve un allarme più veloce? Può non servire a nulla: devi misurare l'intera latenza fino all'intervento.

2. Big Data: formato, scala, qualità e unità

English definitions to practise: *“Structured data follow an explicit tabular schema; semi-structured data have flexible tags or keys; unstructured data lack a ready-made table.” “The five Vs are volume, velocity, variety, veracity and value.”*

Un ordine in un database è spesso **structured**: ogni riga ha campi definiti. Un evento JSON con chiavi flessibili è **semi-structured**. Testo libero, immagini e audio sono **unstructured** rispetto a una tabella pronta [L1 pp.29–40; A25 §1]. La categoria riguarda la rappresentazione, non la verità del contenuto: un CSV ordinato può contenere importi sbagliati, una foto può avere metadata accurati. Un CSV con colonne definite può essere trattato come strutturato anche se il parlato accosta CSV e JSON. Per analizzare un testo bisogna estrarre attributi, ma l'estrazione può sbagliare e va validata.

Le **5 V** pongono domande operative [L1 pp.36–40]. *Volume*: quanti dati e a quale costo conservarli? *Velocity*: quanto presto servono? *Variety*: come collegare formati? *Veracity*: misure, provenienza, mancanti e bias sono affidabili? *Value*: quale esito migliora davvero? Nessuna dimensione, presa da sola, definisce una soglia universale di Big Data. “Garbage in, garbage out” non significa che un algoritmo non possa individuare un errore; significa che se etichette, sensori o campione sono inadeguati, una risposta elegante può essere sbagliata. La “mappa non è il territorio” della parte Rizzi ricorda che una misura omette sempre contesto [A25 §1; E25 §2–3].

Unità, esercizio svolto. Le slide riportano una stima storica di circa 175 ZB/anno, che divisa per 365 fa circa 0,48 ZB/giorno = 480 EB/giorno; il grezzo PLAUD scambia l'unità per GB. Sono grandezze di una previsione del 2019 per il 2025, **non una misurazione osservata nel 2026** [A25 §5; L1 p.12]. Con prefissi decimali, 1 ZB = 10^21 byte e 1 EB = 10^18 byte; dunque 175 × 10^21 / 365 ≈ 4,79 × 10^20 byte/giorno. 1 YB = 10^24 byte, mentre 1 YiB = 2^80 byte: non mescolare prefissi decimali e binari [A25 §5; L1 p.32]. Una slide Formula 1 attribuisce 11 TB a un **team nel weekend**, non a una singola auto, e quel numero non è stato verificato indipendentemente. Anche l'“80–90% non strutturato” nel parlato non è una percentuale universale da ripetere senza periodo e fonte.

Un **digital twin** è una rappresentazione di un oggetto/processo aggiornata con dati e usata per osservare o simulare scenari [E25 §4]. Nell'esempio didattico della lavatrice, sensori di vibrazione e temperatura potrebbero aiutare ad anticipare guasti. Non è un doppio perfetto della macchina: controlla che i sensori siano tarati, il modello distingua uso intenso da guasto e l'intervento sia meno costoso del fermo. La stessa cautela vale nei settori citati da Campana — retail, salute, finanza, energia, trasporto — perché l'errore costoso cambia da uno all'altro [A25 §1, Campana 26–43′].

3. Dalle fonti al record corretto: unità di analisi, join e latenza

English definitions to practise: *“A join combines records using a key that refers to the same entity.” “Decision latency is the time from an event to the last useful action, including data arrival, computation and human response.”*

Campana distingue fonti transazionali (ERP/CRM), sensori, interazioni digitali e API esterne [L2 pp.2–11; A29 §§1–2]. Registrano fenomeni diversi. Vendite mostrano acquisti al prezzo e disponibilità offerti; non misurano desiderio non soddisfatto. Un sensore richiede unità, calibrazione e timestamp affidabile. I social selezionano chi partecipa. Una API può cambiare schema o licenza. Prima di integrare, definisci la **unità di analisi**: persona, visita, abbonamento, ordine o paese? Un identificativo tessera cambiato al rinnovo può far apparire due clienti dove ce n'è uno. Un join uno-a-molti può moltiplicare il valore monetario se la chiave prodotto compare due volte. Controlla cardinalità, chiavi mancanti, righe unmatched e totali prima/dopo [E29 §1].

Anche la **granularità** conta. Un meteo giornaliero per città e ingressi orari in palestra non hanno la stessa scala. Per usarli insieme bisogna specificare zona, intervallo e qualità del proxy. Correlare pioggia cittadina con una cancellazione individuale non dimostra la causa. E conservare “tutto per l'AI” è una cattiva regola: scopo, rappresentatività, qualità, permessi e tempo di conservazione precedono l'archivio [L2 p.3; E29 §1].

Batch processing elabora gruppi a intervalli; **stream processing** tratta eventi in arrivo [L1 pp.56–59; L2 pp.12–19]. Scegli con una timeline. Esempio **ipotetico**: frode alle 10:00, evento disponibile 10:02, modello 10:03, intervento umano 10:20, pagamento irrevocabile 10:05. Ridurre il calcolo da 1 minuto a 10 secondi non salva la decisione se l'intervento arriva alle 10:20. Serve un'azione automatica reversibile prima delle 10:05, oppure riprogettare il processo. Al contrario, un report mensile o riconciliazione notturna può funzionare in batch con minore costo. Molte aziende usano entrambi: segnale rapido per allarme, elaborazione periodica per riconciliare. Nello stream controlla duplicati, eventi fuori ordine, rete e falsi allarmi; nel batch considera il danno del ritardo [E29 §3]. Una fonte più rapida ma errata accelera l'errore.

4. Quattro analytics, quattro domande

English definitions to practise: *“Descriptive analytics asks what happened; diagnostic analytics asks why; predictive analytics estimates what may happen; prescriptive analytics compares actions.”* Sono categorie di domande, non una sequenza che garantisce causalità [L1 pp.53–54; A25 §1].

Una dashboard che mostra il 15% di clienti persi è **descriptive**, purché “cliente perso” e periodo siano definiti. Cercare se la perdita coincide con consegne in ritardo è **diagnostic**, ma la coincidenza non è ancora una prova che il ritardo l'abbia causata. Stimare i clienti a rischio nel prossimo mese è **predictive**. Confrontare costo e possibile beneficio di contattarli è **prescriptive**. Dopo l'azione occorre misurare l'effetto. La slide elenca quattro tipi, non un quinto tipo chiamato “monitoring”; nell'ASR il primo passaggio è chiamato per errore predictive [A25 §1]. I numeri del caso clientela nel parlato sono illustrativi, non un'azienda misurata.

Data analysis esamina dati per rispondere a una domanda; **data analytics** include metodi e processo di uso; **data science** progetta e valida modelli; **business intelligence (BI)** organizza report e strumenti decisionali [L1 pp.47–55]. I confini lavorativi si sovrappongono. È falso che analytics guardi solo il passato: predictive/prescriptive analytics guardano avanti. Un grafico, comunque, non decide da sé. Per ogni analisi scrivi: chi userà il risultato, quale azione è possibile, quale errore costa di più, come confronti con la situazione corrente.

5. Casi Rizzi del 29 settembre: la stessa AI richiede prove diverse

Lo studio sulla **conversione a demenza** è materiale su previsione e limiti inferenziali, non uno strumento clinico [L2 pp.31–34; A29 §4; E29 §4]. Nello studio NACC di Arnold e colleghi riportato dagli appunti: 9.606 partecipanti, 877 conversioni, 13 fattori, follow-up medio circa sei anni. Sono distinti dai 14 fattori della Lancet Commission 2024, che rispondono a un'altra domanda. XGBoost combina alberi; SHAP spiega quali variabili hanno contribuito alla previsione del modello; survival analysis considera tempo all'evento e osservazioni censurate. Un contributo SHAP alto non prova che cambiare quella variabile prevenga l'esito. In particolare, BMI più alto associato a minore rischio osservato in quel campione **non** significa “aumentare peso previene demenza”: perdita di peso prima della diagnosi, età e selezione possono confondere la relazione.

Quattro verifiche non intercambiabili: **discrimination** (ordina casi e non casi? ROC AUC nello studio 0,732), **calibration** (fra i casi con rischio stimato 20%, quanti hanno davvero l'esito nell'orizzonte?), **generalisation** (funziona in altri centri/periodi?) e **utility** (un intervento migliora esiti al netto degli errori?). Lo studio riporta sensibilità 0,702, specificità 0,637, accuracy 0,643, PR AUC 0,208; non confonderle con probabilità individuale. **Calcolo didattico distinto dallo studio:** su 1.000 persone con prevalenza 9%, 90 casi; un test con sensibilità 70% trova 63 veri positivi e perde 27, specificità 64% lascia circa 328 falsi positivi fra 910 non casi. PPV = TP/(TP+FP) ≈ 63/(63+328) = 16%. Un risultato positivo non equivale quindi al 70% di probabilità personale. Cambiando popolazione e prevalenza cambia anche PPV. Non applicare questi numeri a decisioni cliniche reali.

Il caso **grandine/alluvione** usa detect → match → predict → act → verify → learn [L2 pp.35–37; E29 §5]. Un evento meteorologico deve essere collegato a immobili e vulnerabilità reali. Perdita attesa ≈ probabilità evento × danno condizionato all'evento è una formula concettuale; indirizzo, esposizione, franchigia e verifica del danno restano necessari. Il caso **Refik Anadol, Machine Dreams: Rainforest** illustra trasformazione creativa di dati in esperienza culturale [L2 pp.38–40]; la prova di valore è diversa dalla validazione di una previsione ecologica. Il caso **moda** distingue attention → search → explore → purchase → keep/return [L2 pp.41–43]. Un picco di like o ricerche può dipendere da una celebrità; margine dopo resi, capacità e lead time servono prima di produrre una collezione. I marchi citati oralmente non certificano sistemi proprietari o profitti specifici.

Nel **fitness challenge** la slide chiede 8–10 touchpoint con dato, fonte e uso, due problemi di qualità, un rischio privacy e due opportunità [L2 pp.44–45]. Esempio **ipotetico**: prenotazione di un corso non è presenza; collega sistema booking e tornello solo se gli ID e i timestamp sono affidabili. No-show rate = (prenotazioni valide − presenze collegate) / prenotazioni valide, se il denominatore >0. Con 30 prenotazioni e 20 presenze, il tasso apparente è 10/30 = 33,3%, ma se alcuni accessi mancano dal tornello la misura sovrastima i no-show. Prima di cambiare capienza controlla lista d'attesa, richieste

respinte e cancellazioni. Dati sanitari di un assessment richiedono scopo e protezioni diverse da semplici orari: la possibilità tecnica di un join non autorizza il riuso per marketing. Il pitch preparato su un centro fitness locale è materiale di esercizio, non prova di implementazione o risultati aziendali.

La piattaforma **Databricks** compare nelle slide L2 pp.20–29 e nella parte finale registrata di Campana. Notebook, catalogo, query SQL e dashboard sono strumenti. Una SELECT * restituisce righe, non chiarisce se ogni riga sia una visita o una persona. La registrazione disponibile si ferma all'introduzione: le slide non dimostrano che tutta la demo sia stata eseguita oralmente [E29 §7].

6. Dal problema al machine learning

English definitions to practise: *"Task is what the system must learn to do; performance is how success is measured on new cases; experience is the data or feedback it learns from."* È lo schema **T–P–E** della lezione Rizzi del 6 ottobre [L3 pp.6–10; A06 §§1–2].

Per una coda di reclami: **T** classificare urgenza; **P** casi urgenti persi, falsi allarmi, tempo alla risposta e costo; **E** reclami storici etichettati. Testare sui medesimi messaggi del training può premiare memoria. Un test temporale successivo, con categorie coerenti e confronto con regola semplice/operatore, assomiglia meglio all'uso futuro. Se i reclami urgenti sono rari, 95% di accuracy totale può nascondere molti casi urgenti persi. ML è utile quando la regola è difficile da scrivere ma esiste segnale apprendibile e il task ricorre. Se basta applicare un'aliquota ufficiale stabile, usa una regola verificabile. Se una lotteria è corretta e indipendente, la storia non predice il numero seguente: un algoritmo complesso non inventa il segnale [E06 §1].

Supervised learning usa esempi con label; **unsupervised** cerca strutture senza label; **semi-supervised** sfrutta poche label e molti esempi senza; **reinforcement learning** apprende da reward per azioni in sequenza [L3 pp.12–19; E06 §2]. La domanda utile è da dove arriva il feedback. Per reclami già classificati, supervised; per esplorare gruppi di reclami, unsupervised; per 500 recensioni etichettate su 100.000, eventualmente semi-supervised; per scegliere una sequenza di azioni in una simulazione valida, reinforcement. Una label sbagliata, un cluster interpretato come categoria "naturale" o un reward che premia solo velocità possono produrre decisioni dannose. La slide 20 colloca **data mining, KDD, data analysis e pattern recognition** come ambiti vicini, non altre quattro modalità di feedback.

AI è il contenitore ampio, **ML** una famiglia che apprende dai dati, **deep learning** una famiglia di ML con reti profonde, **generative AI** genera nuovi contenuti e un **LLM** è un modello linguistico profondo che genera sequenze di token [L3 pp.24–35; E06 §3]. Symbolic AI usa regole/rappresentazioni esplicite; può convivere con ML. Un **decision tree** rende ispezionabile una sequenza di condizioni, ma può usare un indizio spurio. Una **neural network** può modellare relazioni complesse, ma i pesi non equivalgono automaticamente a spiegazioni umane. Se foto di mele nel training hanno tutte sfondo bianco e pere sfondo nero, entrambi i modelli potrebbero imparare lo sfondo. Testare foto nuove con sfondi variati verifica generalizzazione. La probabilità 0,8 prodotta da un modello va controllata per **calibration** prima di chiamarla "80% di certezza reale".

Un LLM trasforma input in **token**, usa contesto e parametri appresi per stimare distribuzioni di token successivi, quindi genera testo. **Attention** nel Transformer combina informazioni della sequenza; **temperature** modifica la variabilità della selezione [L3 pp.31–35; A06 §4]. Una temperatura più bassa può rendere l'output più ripetibile, non più vero. Il modello non è un database di record certificati; può inventare

data, numero o pagina. La verifica di una risposta richiede aprire fonte e controllare contenuto, periodo e denominatore. Se un LLM scrive una comunicazione sui ritardi, valida separatamente la previsione numerica e la fedeltà del testo. La slide su *Absolute Zero Reasoner* è frontiera di ricerca e riguarda task verificabili generati in auto-play; “zero data” non significa assenza di pretraining o capacità generale senza prove [E06 §3].

7. Data Lake: dal file grezzo alla cifra affidabile

English definition to practise: *“A data lake stores different data formats, often in their original form, but reliable use still requires metadata, quality checks, access control and lineage.”* L3 pp.36–48 tratta il lake su slide, ma gli appunti non identificano una spiegazione orale corrispondente; L4 pp.2–14 approfondisce il tema per iscritto e per il 13 ottobre non c'è audio locale [A06 §5; E13 §§1–2].

Il flusso della slide è **sources** → **ingestion** → **storage** → **distillation** → **processing** → **insights** → **action** [L4 p.6]. *Ingestion* acquisisce file/eventi e registra origine/versione; *storage* conserva dati raw o preparati; *distillation* pulisce e struttura; *processing* calcola; *insight* rende il risultato interpretabile; *action* lo collega a una scelta. HDFS nella slide è un possibile storage, non requisito di ogni lake. **Schema-on-read** vuol dire definire uno schema utile quando prepari/leggi un dataset, non rinunciare a ogni controllo all'ingresso. Lake e warehouse possono coesistere; non esiste una regola universale “lake piatto, warehouse cartelle”.

Cinque controlli trasversali: **metadata/catalogue** (che cosa significa revenue, unità, fonte, periodo, owner); **data quality** (mancanti, tipi, duplicati, range, coerenza); **security/governance** (chi accede e per quale scopo); **lineage** (da quale record e trasformazione deriva il KPI); **audit** (chi ha cambiato regola e quando) [L4 pp.8–14]. *Authentication* verifica chi sei, *authorization* cosa puoi fare. Un report può cambiare perché una nuova importazione duplica vendite o perché la definizione di ricavo passa da lordo a netto: prima di chiamarlo trend di mercato, usa lineage e audit. Conservare il grezzo aiuta a ricostruire, ma non implica conservazione illimitata di dati personali. Le fasi di maturità in L4 pp.12–13 sono uno schema didattico, non una statistica sulle imprese.

I quattro formati di L4 pp.15–23 rappresentano lo stesso esempio musicale in modi diversi: CSV è testo tabellare semplice ma con tipi impliciti; XML usa tag e gerarchie e può avere schema formale; JSON usa oggetti/array e si presta a API/eventi; Parquet è binario colonnare, utile per leggere poche colonne su molte righe con tipi/compressione. Nessun formato “migliore” sempre. Se una persona deve correggere tre prezzi, CSV è pratico; se una dashboard legge country e streams su milioni di record, Parquet può ridurre lettura e spazio. La velocità dipende da query, dimensioni e layout: **Parquet non pulisce duplicati o bug di significato**. Conservare JSON raw e pubblicare una tabella analitica tipizzata è un percorso possibile. La slide JSON contiene virgolette tipografiche non valide per un parser, dettaglio da correggere se copi il codice [E13 §3].

8. Laboratorio reale dei formati misti: fare i conti e riconciliare

Il ZIP di L4 pp.24–25 contiene customers.csv, products.xml, sales.json, forecast.parquet. La missione è confrontare **actual e forecast per mese × regione**. Nel file, 4 clienti; prodotto P03 appare due volte identico nell'XML; sales.json ha 9 righe fisiche ma 8 sale_id perché S008 è ripetuta. Prima del join controlla chiave e cardinalità. Con due P03, ogni vendita P03 si raddoppia; con S008 doppia si conta due volte quella vendita. Questi sono **record dell'esercizio**, non vendite di un'azienda reale [E13 §4].

Calcolo passo passo sui dati del ZIP. Definisci revenue_i = quantity_i × unit_price_i in **unità monetarie**, perché il file non specifica valuta. S001: P02, 1.200 unità a 14,99 → 1.200 × 14,99 = 17.988,00, gennaio × South. Quantità 1.200 è anomala rispetto al piccolo campione: controllarla, non cancellarla senza prova. S003: P03, 80 × 44,99 = **3.599,20**; se il join usa entrambi i P03, comparirebbe **7.198,40**. Deduplicando solo copie identiche di P03 e S008, otto vendite uniche danno **35.677,80** actual totale. Un join ingenuo lascia **45.973,80**, sovrastima **10.296,00**. Il gruppo marzo × North ha S006, 100 × 44,99 = 4.499,00; aprile × West contiene S008, 2.197,80 dopo deduplica. Conta sale_id unici, righe unmatched e totale prima/dopo: non basta che il grafico “sembri giusto”.

actual_(m,r) = Σ_i revenue_i per vendite con mese m e regione r. Unisci forecast sulla **coppia** (month, region), non sul solo mese. variance_(m,r) = actual_(m,r) – forecast_(m,r) in unità monetarie. attainment% = 100 × actual/forecast se forecast > 0; se forecast = 0, l'indicatore non è definito e va etichettato. **Esempio inventato per la formula:** actual 120, forecast 100 → variance +20 e attainment 120%; non viene dal ZIP. La spiegazione locale letta non aveva ancora decodificato i valori di forecast.parquet: non presentare un variance reale del dataset senza leggerlo e verificare perimetro e valuta. Una cifra actual corretta e un forecast di tutte le regioni confrontati con North generano comunque una variazione priva di significato.

9. Che cosa produce l'AI: previsione, classe, ranking o azione?

English definitions to practise: *“Prediction estimates an unknown outcome; classification assigns a label; personalization ranks options for a person and context; automation executes or routes an action under rules.”* L4 pp.26–32 usa lo stesso contesto commerciale per far scegliere il prodotto giusto, non per obbligare a usare quattro modelli insieme.

Prediction: “quante consegne arriveranno domani?” Output numero/intervallo/probabilità. Per tempi di consegna, MAE = (Σ |tempo_reale – tempo_previsto|)/n, in minuti o ore se entrambi lo sono. **Esempio inventato:** errori di 10, –20 e 15 minuti → MAE (10+20+15)/3 = 15 minuti. Una finestra “14–17” va valutata anche per copertura e calibrazione; MAE basso non basta. Usa solo dati disponibili al momento dell'ordine, non la vera ora d'arrivo appresa dopo.

Classification: “questa transazione è frode?” Output score, soglia, classe e possibile revisione [L4 pp.29,36]. Con classe positiva = frode: TP frodi segnalate, FP pagamenti leciti segnalati, FN frodi perse, TN leciti non segnalati. **Esempio inventato:** 1.000 pagamenti, 20 frodi; TP=15, FP=15, FN=5, TN=965. precision = TP/(TP+FP) = 15/30 = 50%; recall = TP/(TP+FN) = 15/20 = 75%; false-positive rate = FP/(FP+TN) = 15/980 ≈ 1,53%; accuracy = (TP+TN)/1000 = 98%. Approvare tutto darebbe ugualmente

98% accuracy ma recall frodi **0%**: accuracy sola nasconde l'esito raro. Se abbassi soglia e trovi 18 frodi ma segnali 60 leciti, recall sale a 90%, precision scende a 18/78 ≈ 23,1%. La scelta dipende da perdita delle frodi, frizione sui clienti e capacità di revisione. F1 = 2PR/(P+R) riassume precision/recall quando definito, non il costo economico.

Personalization: “quale brano mostrare a questa persona?” Output ranking, non una classe universale [L4 pp.30,33–34]. Segnali come replay, skip, like e contesto possono aiutare; ma un click dipende anche da ciò che la piattaforma ha mostrato. *Content-based* usa caratteristiche degli oggetti, *collaborative filtering* somiglianze tra utenti, *context-aware* situazione corrente, *hybrid* combina. Valuta soddisfazione, scoperta, diversità e retention oltre ai click, rispettando privacy e il rischio di popularity bias.

Automation: “instrada o esegui un'azione”. Nel caso illustrativo mutuo [L4 p.31], debt-to-income ratio = pagamenti mensili del debito / reddito mensile lordo, se reddito >0. **Esempio inventato:** 600+200 di rate e 3.200 reddito → 800/3200=25%. È una sola variabile; non autorizza da sola approvazione/rifiuto. Un sistema può controllare documenti e mandare casi complessi a una persona; decisioni ad alto impatto richiedono spiegazioni, controllo di equità, audit e possibilità di ricorso. Non confondere un diagramma di slide con una procedura bancaria realmente adottata o conforme a ogni legge.

10. Prevedere non è dimostrare l'effetto di una scelta

English definition to practise: *“Correlation describes how variables co-vary; causal impact asks what outcome changed because of an intervention, relative to what would have happened without it.”*

La distinzione di L4 pp.35–38 tiene insieme tutto il corso. **Hindsight** spiega un esito già osservato; **prediction** usa soltanto ciò che era disponibile prima dell'esito. Se per prevedere il ritardo usi l'ora di arrivo effettiva, introduci **data leakage**: il test sembra eccellente ma non funzionerà al momento della decisione. Per evitarlo, fissa timestamp decisionale, dividi training e test nel tempo quando opportuno, adatta pulizia/normalizzazione soltanto sul training e valuta casi non visti. Anche un test storico buono non dimostra miglioramento del business.

La **correlazione** può nascere da causalità in una direzione, direzione opposta, variabile comune o selezione del campione. Nell'esercizio “più gioco d'azzardo, più madri sole?” ci sono **due analisi locali con definizioni Y diverse**, da non fondere. La versione successiva Compiti/2026-10-06 Gambling e madri sole/analisi-e-fonti.md usa Eurostat HBS 2020 hbs_exp_t121 CP0943: spesa annua dichiarata per giochi di sorte per nucleo in PPS, **non** puntate totali o numero di giocatori. Y = 100 × donne adulte in nuclei con un solo adulto e figli sotto i 18 anni / tutti i nuclei con figli sotto i 18 anni, unità migliaia che si cancellano. Su 21 paesi UE, Pearson r = –0,000046, Spearman –0,051999: nessuna associazione positiva visibile con queste misure. Controllo 2015 stessi paesi r ≈ –0,0177, quota spesa 2020 r ≈ +0,0337. Questo non prova che la relazione sia sempre zero o che non vi sia un effetto individuale. Le rilevazioni HBS hanno periodi, autosegnalazione e comparabilità imperfetti; il dato 2020 non descrive il 2026. Il nucleo “una adulta con figli” non è necessariamente una madre non sposata e può escludere chi vive con altri adulti.

La precedente proposta Compiti/2026-10-06 Team Work 3/Gambling and single mothers/2026-10-06__testi-e-fonti.txt usa invece **census family nuclei con figlio residente sotto 25**, 24 paesi e confronto 2020-wave/2021: Pearson circa –**0,37**. È un'unità familiare diversa da household e una diversa selezione di paesi. Il risultato comune è **“i dati scelti non sostengono l'ipotesi positiva”**; entità

e robustezza della direzione dell'associazione non sono stabili al cambio di definizione. Non citare –0,37 come se fosse il coefficiente della presentazione successiva a 21 paesi, né dire che il gioco “protegge” dalla monoparentalità. È un esempio concreto di sensibilità alla definizione, non una scoperta causale. Una correlazione tra paesi non descrive il comportamento di una singola persona: sarebbe **ecological fallacy**. Per studiare causalità servirebbero esposizione individuale, sequenza temporale e fattori concorrenti misurati, con disegno credibile.

Un **A/B test** assegna casualmente utenti eleggibili a versione A e B, misura lo stesso outcome nella stessa finestra e confronta gruppi [L4 p.38]. Se A compra 10 volte su 100 (10%) e B 12 su 100 (12%), differenza osservata **+2 punti percentuali**, non “+2% relativo”; il +20% relativo sarebbe (12–10)/10. Con 100 per gruppo, la differenza potrebbe essere rumore: definisci campione, metrica e durata prima di guardare i dati, riporta incertezza. Se promuovi solo clienti già propensi a comprare, il loro tasso alto non prova l'effetto della promozione. Per il profitto usa profitto per **cliente assegnato**, includendo costo dello sconto, non soltanto numero ordini tra chi ha cliccato. Randomizzazione valida aiuta a stimare effetto medio **di quella variante in quel contesto**, non garantisce trasporto a ogni futuro caso.

Un raccomandatore crea un **feedback loop**: mostra → l'utente vede/clicca → il nuovo dato influenza la prossima raccomandazione [L4 p.37]. L'oggetto mostrato in cima riceve più click anche per la sua posizione; l'assenza di click su ciò che non è stato mostrato non prova disinteresse. Per valutare, registra esposizione, prova qualche alternativa e monitora soddisfazione e diversità. Le slide L4 p.40 citano Zillow, Amazon recruiting ed eBay paid search: i primi due restano esempi riportati nelle slide, senza verifica primaria qui; per eBay il working paper NBER 2014 conferma che in quel contesto gli esperimenti diedero rendimenti inferiori alle stime osservazionali, non una legge per tutta la pubblicità [E13 §7].

11. Sei domande di verifica create per studiare

Sono **esercizi originali**, non domande annunciate. Prova prima senza guardare il feedback. Le risposte modello sono brevi per allenare il ragionamento, non testo da consegnare come proprio.

1. **Un negozio ha due CSV da 100 righe. Dopo un join per product_id ne vede 120. Qual è il primo controllo?** A. Scegliere Parquet. B. Contare quante righe ha ogni product_id su entrambi i lati e verificare cardinalità. C. Fare un grafico. D. Cancellare 20 righe casuali. **Risposta B.** Una chiave non univoca può moltiplicare le righe; formato e grafico non correggono la logica. Nel ZIP L4, P03 è il caso reale da ricordare.

2. **Una frode rara è classificata sempre “lecita” e ottiene 98% accuracy. Quale metrica rivela subito il difetto?** A. Recall della classe frode. B. Dimensione file. C. Numero di colonne. D. Velocità del grafico. **Risposta A.** Con nessuna frode segnalata, TP=0, quindi recall=0/(0+FN)=0; accuracy alta deriva dalla classe maggioritaria.

3. **Perché forecast e actual devono essere uniti su mese *e* regione?** A. Perché Databricks lo richiede sempre. B. Per evitare di confrontare popolazioni/perimetri diversi e duplicare forecast. C. Per cambiare valuta. D. Per aumentare il numero di righe. **Risposta B.** La chiave definisce l'unità di confronto. Unirli solo per mese può accoppiare South con North.

4. **Un team aumenta la temperatura dell'LLM per ottenere il dato ufficiale corretto. È una verifica?** A. Sì, se tre risposte coincidono. B. Sì, se il testo è fluido. C. No: deve leggere la fonte ufficiale e controllare data, definizione e numero. D. No, perché gli LLM non generano testi. **Risposta C.** La

temperatura cambia campionamento, non verità o provenienza.

5. **Un trend di ricerca scarpe cresce durante una promozione. Che cosa manca per ordinare 10.000 pezzi?** A. Solo più like. B. Vendite/preordini, prezzo, resi, margine, lead time e confronto senza promozione. C. Un formato XML. D. Una dashboard colorata. **Risposta B.** Attenzione e domanda redditizia sono stadi diversi; la promozione altera il segnale.

6. **Due definizioni corrette di "madri sole" danno correlazioni −0,000046 e −0,37. Quale conclusione regge?** A. Il gioco causa meno monoparentalità. B. Ogni effetto è esattamente zero. C. Nei campioni e misure scelti non emerge la relazione positiva ipotizzata; grandezza/direzione richiedono cautela. D. Basta scegliere il coefficiente più forte. **Risposta C.** Cambiando unità, età e paesi cambia il coefficiente; nessuna delle due è prova causale.

Due mini-risposte modello per uno scritto o un orale, inventate.

"Quando scegliere batch o stream?" *Parto dall'ultima azione ancora utile, non dalla potenza del software. Se una frode può essere fermata entro pochi secondi, un segnale rapido può servire; se il processo umano richiede venti minuti, occorre ridisegnarlo o evitare l'automatismo. Per un report mensile basta spesso batch. Valuto costo, eventi duplicati, falsi allarmi e danni evitati rispetto al processo corrente.* Questa risposta usa definizione, meccanismo, caso e limite [L2 pp.12–19].

"Una correlazione basta per adottare un intervento?" *No. Definisco X, Y, unità, periodo e campione; verifico join e confondenti. Una correlazione può aiutare a formulare un'ipotesi o prevedere, ma l'effetto di una scelta richiede confronto con ciò che sarebbe successo senza l'azione. Un A/B test ben disegnato può stimare l'impatto medio della variante, riportando incertezza. Nel caso del gioco e dei nuclei familiari, cambiare definizione modifica perfino la dimensione del coefficiente.* [L4 pp.35–38; analisi Eurostat locali].

12. Come ripassare senza confondere fonti e risultati

Prima spiega a voce la catena **decisione** → **dati** → **qualità** → **metodo** → **azione** → **misura** usando il negozio. Poi ricostruisci a mano il join del ZIP (S003 e P03), una matrice di confusione con formule e il tasso del fitness. Infine prova una domanda nuova: "una palestra vuole anticipare no-show": definisci unità, timestamp, dati disponibili prima della lezione, baseline, azione praticabile, metrica e privacy. Se non riesci a distinguere previsione del no-show dall'effetto di un promemoria, rileggi §10. Per un inglese semplice, usa le definizioni in corsivo e prova a spiegare ogni limite senza tradurre parola per parola.

Confini della guida. Il 25/09 ha due registrazioni e slide; l'audio non è stato riascoltato integralmente. Il 29/09 la seconda registrazione non copre ogni minuto programmato e non prova l'intera demo Databricks. Il 06/10 il Data Lake è slide, non parlato attestato; il pomeriggio documenta laboratorio e pitch, non una lezione frontale su ogni pagina. Per il 13/10 il contenuto è slide L4 e ZIP, senza registrazione/trascrizione locale. Gli esempi e numeri inventati sono marcati; le percentuali dei casi aziendali non verificati non sono diventate fatti. Il documento L4 annuncia un warm-up da 15 domande ma **non contiene quelle domande**, né fissa un futuro assessment. Segui comunicazioni correnti del corso per qualsiasi consegna o verifica.

Letture Canvas: come usarle senza trasformarle in programma obbligatorio

La pagina Reading Materials del corso elenca manuali, libri e quattro articoli McKinsey. Sono **risorse disponibili**; nessuna lettura locale o annuncio qui verificato impone di leggere integralmente tutti i libri per

il prossimo subcomponent. I quattro articoli sono utili per interrogare le scelte aziendali del corso, ma le loro cifre e casi hanno il proprio periodo e perimetro.

- *From raw data to real profits* (2024) porta la catena del §1 a un prodotto dati: bisogno reale del cliente, vantaggio nei dati/know-how, prodotto integrato nel workflow e modello economico. I casi Walmart Luminate, KPI dei materiali edili e MVP pharma illustrano opzioni differenti; **possedere dati non crea monetizzazione automatica**. Chiedi privacy, diritti IP, prezzo, capacità di vendita e scala prima di chiamare un dataset “nuovo business”.

- *The state of AI in 2023* è una survey di aprile 2023 su 1.684 rispondenti, con adozione **dichiarata** della generative AI vicina a un terzo nel campione. Segnala divario fra uso e mitigazione dell'inaccuratezza, e associa high performers a innovazione/MLOps. Sono autosegnalazioni e correlazioni del 2023, non stato 2026 né prova che MLOps causi performance. Collegala al §6–7: adozione, controllo dell'output e monitoraggio sono prove separate.

- *The data dividend: fueling generative AI* (2023) propone sette azioni che vanno dal caso d'uso e valore ai controlli lungo source → preprocessing → prompt → output, con PII, data engineering, KPI e costi/FinOps. Distingue Taker, Shaper e Maker come livelli di costruzione; un vector database può essere utile per alcuni retrieval workflow, **non requisito di ogni applicazione AI**. Il consiglio pratico è scegliere l'architettura minima che consenta la decisione e la verifica.

- *Adopting a smart data mindset in a world of big data* (2021) spiega perché esperti di processo e caratteristiche fisiche utili possono contare più del semplice volume. I casi consulenziali parlano di un flowmeter virtuale, modello dryer con Darcy–Weisbach e riduzione del tempo di fusione; percentuali riportate come +20% throughput, +8% e –10% sono **esiti di quei casi**, non benchmark universali. Il nesso col corso è Frame/Acquire/Build/Adopt/Monitor: chi conosce la macchina definisce variabili e limiti, poi testa l'effetto nell'uso.

Come interpretare la domanda dell'80% senza scrivere l'elaborato al posto dello studente

Il brief ufficiale Canvas (file 131911, pp.2–4) chiede un **executive report per una media impresa che valuta se investire in Big Data e AI**. Il testo deve identificare opportunità, fattori critici di successo, rischi/limiti, impatto sulle decisioni dei manager, potenziale trasformazione digitale e una raccomandazione finale. È l'assegnazione del blog da 80%, **non** la traccia confermata del prossimo subcomponent. Per studiarla, prendi un'azienda **ipotetica**, definisci una decisione concreta, stima dati minimi e confronto con baseline, poi costruisci una matrice di condizioni per procedere o fermarsi. La conclusione può essere condizionata: per esempio “pilotare un solo caso d'uso dopo pulizia e verifica dei diritti; ampliare solo se margine e servizio migliorano nel test”. Sono domande di preparazione; l'elaborato effettivo deve essere ricerca e scrittura originali dello studente. Il brief usa sia la tolleranza generale del 10% sul conteggio sia “3.200 words maximum” nella domanda: prima della consegna finale, attenersi all'istruzione Canvas/tutor più restrittiva o chiarirla. Template, .docx e Harvard citation sono regole del brief per il portfolio, non formati del ripasso.

Nota sulla fonte di valutazione. La home Canvas identifica il corso come HFARM502. Il brief del Blog e una cella della home riportano invece HFARM512: è una discordanza del materiale ufficiale, non un altro corso. Titolo, docente e consegna individuano Big Data & AI in Business.

PART II — ENGLISH STUDY COMPANION

Big Data & AI in Business — an English study companion

Prepared 18 October 2026 from the corrected notes for 25 and 29 September and 6 October, the written explanation for 13 October, and Rizzi's Lesson 1–4 slides. Rizzi and Campana appear in the first three dated lessons. For 13 October, the available local evidence is the 42-slide PDF and its lab ZIP, not an audio record. A published slide is course material but does not prove that every item was explained orally. Invented examples are marked; none is a real company result.

Assessment boundary. Canvas as checked by the integrating task on 18 October lists module HFARM502: 20% from two in-class subcomponents of 10% each and 80% from a 3,200-word blog. The module descriptor p.3 places the touchpoints in weeks 3–6 and 6–10 and says the tutor gives one week's notice. It lists possible short formats: a roughly 400-word blog, reflection or review, a ten-minute presentation or viva, group seminar and debate. Its 20-question multiple-choice example is expressly for Level 4 modules, not an announced format for this Level 5 course. Canvas Assignment 3007 shows the blog due 13 January 2027 at 16:00, closing 20 January at 16:00; that concerns the separate 80%. The material here does not establish a date, format or questions for the next in-class task. This is independent study support, not text to submit as your own blog.

Source notation. L1 = updated 61-page Week 1 PDF 2026-09-25__big-data-week-1-rizzi-aggiornato.pdf; L2 = BigDataBsnsRizzi2026Lesson2.pdf (45 pp.); L3 = BigDataBsnsRizzi2026Lesson3.pdf (55 pp.); L4 = canvas-133640__BigDataBsnsRizzi2026Lesson4.pdf (42 pp.). A25/A29/A06 mean the dated corrected notes in Lezioni/<date>/pdf/; E25/E29/E06/E13 mean their extended explanations. The 23 September version of L1 has 62 pages, so the page locators below use the updated file. These texts and slides, rather than a fresh full listening of each audio, support this companion.

1. Begin with the decision, not the model

Rizzi asks for the business **why** before the technology [A25 §1; L1 p.5]. Campana follows the data into use: collection → preparation → analysis → distribution → use → reuse [A25 §1]. The central test is not whether a dashboard is attractive or a model accurate in isolation. It is whether a named person can take a different action, and whether the resulting service, margin or risk is better than a credible existing process. A dashboard that is never opened has not completed the data value chain. A prediction that arrives after the last useful intervention may be technically right and commercially useless.

Consider a **hypothetical** retailer facing empty shelves on Saturdays. “Predict demand” is an intermediate task. The operational decision is how many units to reorder and when. Measure stockouts, unsold goods, customer service and margin. Collect daily sales, prices, promotions, stock and supplier lead times. A day with zero recorded sales because the shelf was empty is not proof that demand was zero. Compare the new approach with the current manager's rule on later weeks that were not used to fit the model. Give the manager a way to understand and override the recommendation, and record the outcome. A fall in stockouts after adoption is promising; to attribute it to the model, check other changes such as promotions, supplier performance and seasonality.

The course slide's implementation cycle is **Frame** → **Acquire** → **Build** → **Adopt** → **Monitor** [L1 p.60]. Frame defines the decision and desired outcome. Acquire checks relevance, quality and use rights. Build includes preparation, a simple baseline, a suitable test and a fallback. Adopt places the output where the person acts. Monitor checks costs, mistakes, changed data and actual outcomes. The steps are questions for management, not a promise that every AI project pays for itself. For a simple one-period illustration, ROI = (attributable benefits − costs)/costs. If a system costs 10,000 monetary units and produces 13,000 in **attributable** benefit in the same period, simple ROI is 30%. This is an added teaching calculation, not a formula taught explicitly in the recording; attribution, timing and risk can make the simple ratio misleading [A25 §4].

2. Big Data: distinguish size, representation and trust

Structured data follow a defined schema, such as an order table. **Semi-structured data** have flexible keys or tags, as in JSON or XML. **Unstructured data**, such as free text, images and audio, lack a ready-made analysis table [L1 pp.29–35; A25 §1]. The category does not say whether a record is true or useful. A neat CSV can contain false prices, while an image may have accurate timestamp and location metadata. The precise treatment matters: a CSV with stable columns can be structured even if an oral example groups CSV with JSON. Extracting features from unstructured material adds a new source of error.

The **five Vs** are volume (how much), velocity (how fast data arrive and need handling), variety (how many kinds), veracity (how trustworthy and suitable), and value (whether a decision benefits) [L1 pp.36–40]. There is no universal byte threshold that makes a dataset “Big Data”. More rows can amplify a biased sample or multiply duplicate records. A sensor reading can be precise and still measure the wrong thing. The map-and-territory idea in Rizzi's lesson is a reminder that data are a selected representation of a situation, not the entire situation [A25 §1; E25 §§2–3]. A **digital twin** represents a physical object or process for monitoring or simulation; it needs relevant sensors, validated behaviour and an action worth taking. In the washer example, a change in vibration may precede failure but could instead reflect unusual use or a faulty sensor [E25 §4].

Units matter. An older slide cites a forecast of 175 zettabytes per year for 2025. 175 ZB/year ÷ 365 ≈ 0.48 ZB/day ≈ 480 EB/day; the damaged transcript says gigabytes, which changes the scale radically. This is a historical forecast, not an observed measurement of 2026 [A25 §5; L1 p.12]. Decimal 1 ZB = 10^21 bytes, whereas binary and decimal prefixes must not be mixed (1 YB = 10^24 bytes, 1 YiB = 2^80 bytes). An F1 slide's 11 TB refers to a **team over a racing weekend**, not one car, and is not independently verified here. The spoken “80–90% unstructured” is not a universal current statistic without a dated source.

3. Sources, joins and the time left to act

Campana separates transactional systems such as ERP/CRM, machine sensors, digital/social interactions, and external APIs [L2 pp.2–11; A29 §§1–2]. They see different parts of the world. A sale is an observed purchase under the price and availability offered, not all latent demand. A sensor needs a calibrated unit and clock. A social post comes from a selected group of people. An API depends on its version, licence and reliability. Before combining them, define the **unit of analysis**: person, card, visit, order, membership, country or month? A gym member who receives a new entry card can appear to be two members. A product key that appears twice on the product side of a join can double sales revenue. Check key cardinality, unmatched rows, duplicates and totals before and after each join [E29 §1].

Granularity is the level of temporal, geographic or entity detail. Citywide daily weather and hourly entry scans at one fitness centre are not the same measurement. Joining them may create a rough proxy, not evidence that rain caused a particular cancellation. Nor does availability make data suitable for training: rights, purpose, representativeness, age, retention and quality still matter. “Store everything for AI” can increase risk and noise [L2 p.3; E29 §1].

Batch processing handles data at intervals; **stream processing** handles events as they arrive [L1 pp.56–59; L2 pp.12–19]. Choose through a decision timeline. In a **hypothetical** fraud case, the event occurs at 10:00, data arrive 10:02, the model replies 10:03, a human responds at 10:20 and the payment becomes irreversible at 10:05. Making the model respond ten seconds faster has little benefit unless an authorised action can occur before 10:05. A monthly planning report usually tolerates batch. One firm may stream alerts and reconcile transactions later in batch. Streaming raises duplicate, out-of-order and false-alarm problems; batch can leave harmful events unseen until the next run. Measure end-to-end decision latency and cost of wrong actions, not only CPU speed [E29 §3].

4. Four analytics questions, not four guaranteed achievements

Descriptive analytics asks what happened. **Diagnostic analytics** investigates why. **Predictive analytics** estimates what may happen. **Prescriptive analytics** compares actions [L1 pp.53–54; A25 §1]. If a dashboard says 15% of customers were lost, define “lost” and the period first. If late deliveries coincide with lost customers, you have a diagnostic lead, not yet a proven cause. A churn model can estimate who is at risk. A decision analysis can compare contacting those people with doing nothing, including costs and possible harms. Finally measure the outcome. The course slides name four types; monitoring closes a management cycle but is not a fifth category. The spoken transcript mislabels the first, descriptive, stage as predictive.

Data analysis answers a question through examination of data; **data analytics** includes methods and their use; **data science** often develops and validates models; **business intelligence** supplies reporting and decision tools [L1 pp.47–55]. Job titles and boundaries overlap. It is a mistake to memorise “analytics = past, data science = future”: predictive and prescriptive analytics plainly concern future choices. For any chart, name the intended user, action, unit, period, comparison and most expensive error.

5. The 29 September cases: prediction is not intervention

Rizzi's dementia-risk case teaches evaluation and limits, **not clinical advice** [L2 pp.31–34; A29 §4; E29 §4]. The corrected notes report a NACC study by Arnold and colleagues with 9,606 participants, 877 observed conversions, 13 factors and roughly six years' mean follow-up. That is distinct from the Lancet Commission's 2024 discussion of 14 potentially modifiable factors. XGBoost combines decision trees; SHAP describes contributions to a model prediction; survival analysis considers time to event and censored observations. None of these establishes that changing a strong predictor will prevent the disease. The observed association of higher BMI with lower risk in this sample is especially vulnerable to reverse causality, selection and age effects; it must not become “gain weight to prevent dementia”.

Four separate tests matter: **discrimination** (does the model rank cases and non-cases? reported ROC AUC 0.732), **calibration** (do predicted 20% risks occur about 20% of the time over the stated horizon?), **generalisation** (does performance hold in different centres and periods?) and **utility** (does a real intervention help more than false alarms hurt?). The reported sensitivity is 0.702, specificity 0.637, accuracy 0.643 and PR AUC 0.208; these are not an individual's probability. A simplified **teaching calculation**, separate from the study's patient-level results, shows why base rates matter: among 1,000 people with 9% prevalence, 90 have the outcome. With sensitivity 70%, about 63 are found and 27 missed. With specificity 64%, about 328 of 910 non-cases are falsely flagged. Positive predictive value is approximately 63/(63+328)=16%. It changes if prevalence changes. No clinical threshold is validated by this illustration.

The hail/flood insurance example uses **detect** → **match** → **predict** → **act** → **verify** → **learn** [L2 pp.35–37; E29 §5]. A weather event must be matched to real addresses and vulnerability; a storm map alone is not a loss estimate. Expected loss ≈ event probability × loss conditional on event is a conceptual formula; location, exposure, deductible and confirmed claim still matter. Refik Anadol's *Machine Dreams: Rainforest* illustrates data used for an immersive cultural experience [L2 pp.38–40]; the outcome to assess is not the same as a validated ecological forecast. In the fashion example, distinguish **attention** → **search** → **explore** → **purchase** → **keep/return** [L2 pp.41–43]. A celebrity-driven search spike is not sustained full-price demand. Before producing inventory, check preorders, price, returns, margin and production lead time. Oral brand examples do not prove that a named company had a specific proprietary model or profit.

The fitness exercise asks for 8–10 touchpoints, two quality issues, one privacy risk and two opportunities [L2 pp.44–45]. A booking is not an attendance scan. For a **hypothetical** class with 30 valid bookings and 20 matched entries, apparent no-show rate=(30–20)/30=33.3%, provided the denominator is nonzero. Missing entry scans inflate it; cancellations and waiting lists can change the staffing decision. Health-assessment data demand different purpose and access controls from class times. A technically possible join does not authorise reuse for marketing. The prepared local fitness pitch is an exercise artifact, not proof of deployed results. Databricks appears in L2 pp.20–29 and Campana's recorded introduction; the local recording does not establish that every click of the slide tutorial was performed in class [E29 §7]. A SELECT * query returns records, not an explanation of what a record means.

6. Machine learning: define task, feedback and evaluation

The 6 October Rizzi lesson frames **Task–Performance–Experience (T–P–E)** [L3 pp.6–10; A06 §§1–2]. Task is what the system learns to do, performance is success on **new cases**, and experience is data or feedback used to learn. For complaints: task = classify urgency; performance = urgent cases missed, false alarms, time to response and cost; experience = correctly labelled historical complaints. Evaluating on the training messages can reward memorisation. A time-later test and a simple keyword/human baseline better resemble future work. If urgent complaints are rare, 95% total accuracy can hide unacceptable urgent-case misses. Machine learning is useful when a task repeats and contains learnable signal that is hard to express as a stable rule. An official tax rate is often better encoded as a checked rule. A fair independent lottery gives no useful past pattern for the next draw [E06 §1].

Four learning families differ by **where feedback comes from** [L3 pp.12–19; E06 §2]. **Supervised** learning has labelled examples; **unsupervised** learning explores structure without labels; **semi-supervised** learning combines a small labelled set with many unlabelled examples; **reinforcement** learning uses rewards for sequences of actions. For 500 human-labelled reviews among 100,000, a semi-supervised approach might help after checking the labels. For exploratory groups of complaints, use unsupervised clustering, but do not call a mathematical cluster a natural “loyal customer” group without business validation. Rewarding a delivery agent only for speed can push it toward unsafe or inequitable choices; test safety, legality and service coverage before deployment. The slide also mentions data mining, KDD, data analysis and pattern recognition: overlapping fields, not four extra feedback categories [L3 p.20].

AI is broad; **ML** learns patterns from data; **deep learning** is a family of ML; **generative AI** produces content, and an **LLM** generates language sequences using a deep model [L3 pp.24–35; E06 §3]. Symbolic rules can coexist with learned components. A **decision tree** exposes a path of conditions but may overfit. A **neural network** can represent complex patterns but its weights are not automatically human explanations. If all training photos of apples have white backgrounds and pears black backgrounds, either system may learn the background. Test new images with varied backgrounds. A model output 0.8 needs calibration before it can be treated as an 80% real-world probability.

An LLM tokenises text, uses context and learned parameters to estimate next-token distributions, and produces a sequence. Transformer attention mixes information from the sequence; temperature changes sampling variation [L3 pp.31–35; A06 §4]. Lower temperature may improve repeatability, not factual truth. An LLM is not a certified database. If it claims “85% of students passed”, look for the official register, cohort, period and denominator. If it drafts a delay notice, validate the predicted delay and the wording separately. The *Absolute Zero Reasoner* slide refers to research on self-generated, verifiable tasks; “zero data” does not mean no pretraining or general autonomy without evidence [E06 §3].

7. Data Lake and four file formats

L3 pp.36–48 presents Data Lake concepts in slides without identified oral explanation in the local transcripts. L4 pp.2–14 develops them in writing; there is no local audio/transcript for 13 October [A06 §5; E13 §§1–2]. A **Data Lake** stores different formats, often retaining raw inputs. It still needs meaning and control. The pictured path is **sources** → **ingestion** → **storage** → **distillation** → **processing** → **insights** → **action** [L4 p.6]. Ingestion records source/version; storage retains raw or prepared material; distillation cleans and structures; processing computes; insights interpret; action changes a decision. HDFS is one possible storage technology, not a condition for calling a system a lake. **Schema-on-read** postpones defining the analysis schema until reading or preparation; it does not mean “never validate”. Lakes and warehouses can coexist.

Five controls make numbers trustworthy [L4 pp.8–14]: **metadata/catalogue** states origin, units, meaning, period, owner and permissions; **quality** checks missing values, duplicates, types and plausibility; **security/governance** defines purpose and access; **lineage** traces a KPI back through transformations; **audit** records who changed a rule and when. Authentication asks who is accessing; authorisation asks what they may do. If revenue doubles after a new import, a duplicate or changed gross/net definition may be more plausible than a market boom. Keep a traceable raw copy when lawful and useful, but retention should follow purpose and applicable rules, not “forever”. The four maturity stages in the slides are a teaching progression, not measured statistics about companies.

L4 pp.15–23 displays one musical-streams dataset in **CSV, XML, JSON and Parquet**. CSV is a simple editable flat table with often implicit types. XML expresses hierarchy and can be formally validated. JSON represents objects/arrays common in APIs and events. Parquet stores typed, compressed columns, useful when a large analysis reads a few fields across many rows. None is always fastest or safest. Editing three prices manually favours a simple table; querying country and streams across millions of records may favour Parquet, depending on workload and layout. Parquet does not repair bad joins or duplicates. One possible flow keeps JSON raw and publishes a cleaned typed analytical table. The slide's example JSON contains typographic quotation marks that a parser would reject if copied unchanged [E13 §3].

8. The mixed-format lab: a correct number needs a correct join

L4 pp.24–25 and the accompanying ZIP ask students to combine customers.csv, products.xml, sales.json and forecast.parquet, reporting actual and forecast revenue by **month × region**. The archived ZIP contains four customers; product P03 twice identically; nine physical sales rows but eight distinct sale_id values because S008 repeats. The records are teaching data, not a real company's accounts [E13 §4]. A direct join with both P03 rows doubles every P03 sale; the duplicate S008 compounds the inflation. This is a data-and-join issue, not a Databricks defect.

Declare a deduplication rule only after confirming the duplicate rows are identical. revenue_i=quantity_i × unit_price_i, in **monetary units** because the file supplies no currency. S001 has 1,200 units of P02 at 14.99: 1,200 × 14.99 = 17,988.00, January × South. Its quantity is unusual in this tiny file: investigate rather than deleting it on sight. S003 has 80 units of P03 at 44.99: 80 × 44.99 = 3,599.20, but the careless P03 join would make it 7,198.40. Keeping one copy each of identical P03 and S008 yields eight unique sales and **35,677.80 monetary units** total actual revenue; the naive join produces **45,973.80**, an

overstatement of **10,296.00**. March × North is S006, 100 × 44.99 = 4,499.00; April × West is S008, 2,197.80 after deduplication. Check unique sale IDs, unmatched keys and sums at every stage.

Define actual_(m,r)=Σ revenue_i for the chosen month m and region r. Join forecast on **both** month and region, and verify that each pair has at most one forecast. variance=actual–forecast in monetary units; attainment%=100×actual/forecast only when forecast is nonzero. If forecast is zero, label the ratio undefined. **Invented formula example:** actual 120, forecast 100 → variance +20 and attainment 120%. This is not a ZIP record. The local written source did not decode the numeric forecast values, so this guide makes **no numerical claim about the ZIP's actual-versus-forecast variance**. Comparing one region's actual with an all-region forecast would be meaningless even if both numbers were individually correct.

9. Match the AI capability to the output and error cost

L4 pp.26–32 contrasts **prediction** (number or probability), **classification** (label), **personalisation** (ranking for a person and context) and **automation** (an executed or routed action). One dataset does not justify every use; each output requires its own target, metric, rights and review.

For delivery-time **prediction**, MAE=(Σ|actual_time–predicted_time|)/n, in the same time unit as the observations [L4 p.28]. **Invented calculation:** errors +10, –20 and +15 minutes give (10+20+15)/3 = 15 minutes MAE. Evaluate the coverage and calibration of a delivery window too. A low MAE does not prove an “85% within two days” interval is calibrated. Use information available when the order is placed, not the final arrival time learned afterwards.

For fraud **classification**, positive means “fraud”, not “good” [L4 pp.29,36]. TP true fraud flagged; FP lawful payment flagged; FN fraud missed; TN lawful payment left alone. In an **invented** 1,000-payment case with 20 frauds, suppose TP=15, FP=15, FN=5, TN=965. Then precision=15/(15+15)=50%, recall=15/(15+5)=75%, false-positive rate=15/(15+965)≈1.53%, and accuracy=(15+965)/1000=98%. Approving everything would also score 98% accuracy while detecting **zero** fraud. Lowering the threshold may find more fraud but annoy more legitimate customers. If TP rises to 18 and FP to 60, recall becomes 90% but precision only 18/78≈23.1%. Choose a threshold through loss, customer friction and review capacity. F1=2PR/(P+R) when defined summarises precision/recall but is not a financial cost function.

Music **personalisation** uses signals such as full listens, replay, skip, likes and situation to rank tracks [L4 pp.30,33–34]. Content-based methods compare track features; collaborative methods use patterns among users; context-aware approaches use the moment and device; hybrid systems mix these. A click partly reflects what the service put in view. Popularity for everyone is not the same as relevance for this person. Evaluate satisfaction, discovery, diversity and retention in addition to clicks, with privacy controls.

Mortgage **automation** in L4 p.31 illustrates routing and human oversight, not an approved real bank policy. Debt-to-income ratio=monthly debt payments/gross monthly income when income >0. With **invented** payments 600+200 and gross income 3,200, 800/3,200=25%. That single factor cannot decide a loan. A system may check documents and route complex cases to people. High-impact decisions need reason codes, audit, fairness checks, privacy, override and appeal appropriate to the actual law and process.

10. Correlation, leakage, feedback and causal impact

Hindsight explains an observed outcome; **prediction** estimates an unknown one using only information available at the decision point [L4 p.35]. Using tomorrow's actual sales to “predict” tomorrow's demand is **data leakage**. Fix a decision timestamp, separate training and later evaluation when forecasting, fit preprocessing on training data only and evaluate on unseen cases. Even a valid prediction does not show that taking an action based on it improves outcomes.

Correlation describes co-movement; causal impact asks what changed *because of* an intervention, relative to the outcome without it [L4 pp.35–38]. Two archived versions of the gambling and single-mother assignment make this concrete, and **they must not be merged**. The later analysis Compiti/2026-10-06 Gambling e madri sole/analisi-e-fonti.md uses Eurostat HBS 2020 spending on games of chance per household in purchasing-power standards (PPS), not number of gamblers or total bets. Its Y is 100 × adult women in one-adult households with children under 18 / all households with children under 18. In 21 EU countries, Pearson r≈–0.000046 and Spearman ≈–0.052; the same countries in 2015 give Pearson about –0.0177. This operational “one female adult with children” category neither proves marital status nor necessarily identifies a biological mother, and excludes a mother living with another adult. Survey reporting and national reference periods limit comparison; 2020 does not describe 2026.

An earlier Team Work 3 text used a **different** Y: census lone-mother family nuclei with a child under 25, rather than one-adult households with children under 18, and included 24 countries. It reported Pearson about –**0.37**. A family nucleus can exist inside a larger household; the samples, periods and denominator differ. Both versions fail to support the proposed **positive** association under their chosen measures, but the magnitude and robustness of the direction depend on the definition; these two coefficients are both non-positive. Do not quote –0.37 as if it came from the later 21-country deck; do not claim gambling “protects” anyone. Country-level correlation cannot be assigned to individuals: doing so is an **ecological fallacy**. A causal study would need individual exposure, timing, family transitions, confounders and a credible comparison design.

A well-designed **A/B test** randomly assigns eligible users to A or B, measures the same outcome over the same window, and compares groups [L4 p.38]. If A gets 10 purchases among 100 assigned users (10%) and B 12 among 100 (12%), observed difference is **+2 percentage points**; relative change is +20%. With groups this small, chance variation may explain the gap: define sample, metric and duration before viewing results, and report uncertainty. If an offer goes only to people already likely to buy, their purchases do not establish the offer's incremental effect. For discounts, compare profit per *assigned* customer including the discount cost, not only orders among clickers. A valid test estimates the tested variant's average effect in its context, not a timeless law.

A recommendation system also creates a **feedback loop**: it shows an item, the user reacts, and the reaction trains the next recommendation [L4 p.37]. An item at the top can get more clicks because of placement; an unseen item cannot be judged unpopular from zero clicks. Record exposure and test some alternatives. L4 p.40 mentions Zillow Offers, Amazon recruiting and eBay paid search. The first two are examples on the slide whose details are not independently verified in the local explanation. The eBay field experiment discussed in the 2014 NBER paper supports the narrower lesson that, in that campaign and period, observational paid-search returns exceeded experimental returns; it does not prove all advertising is ineffective [E13 §7].

11. Practise applying the concepts

These are **original drills**, not announced assessment questions. Answer first, then check the reasoning. They are a study method, not paragraphs to submit as personal work.

1. A join of two 100-row files produces 120 rows. What should you check first? **Answer:** key cardinality and repeated product_id values on both sides; a non-unique key can multiply records. Switching to Parquet or choosing a prettier chart will not fix the join.

2. A classifier says every payment is legitimate and boasts 98% accuracy when 2% are fraud. Which metric immediately reveals the failure? **Answer:** fraud recall is zero: TP=0, so TP/(TP+FN)=0 if fraud exists. Accuracy reflects the dominant legitimate class.

3. Why must actual and forecast be joined on month **and** region? **Answer:** they must share the same comparison unit; a month-only join can pair South actual with North forecast and multiply records.

4. Would lowering an LLM's temperature verify an exam date? **Answer:** no. It affects token sampling. Check the current course announcement or official assessment page for the date and definition.

5. Search interest for shoes spikes during a promotion. What is missing before ordering 10,000 units? **Answer:** full-price purchases or preorders, returns, margin, lead time, stock and a comparison period. Attention is not profitable demand.

6. The two gambling assignment definitions yield correlations near zero and –0.37. What conclusion survives? **Answer:** the selected country-level data do not support the proposed positive association; the coefficient changes with definition and sample, and neither value establishes causality.

Model short answer, invented prompt — "When would you use batch rather than streaming?" *I begin with the last point at which an action can still prevent a loss. A fast fraud signal may justify streaming if a safe action can happen in seconds. A monthly planning report can usually run in batch. I would compare total response latency, duplicated events, false alerts, operational cost and avoided loss against the existing process. A faster model alone may not help when the human response remains too slow.*

Model short answer, invented prompt — "Does a correlation justify a business intervention?" *I would first define both variables, the unit, period, sample and join. Correlation may support a hypothesis or help forecast, but it does not isolate the outcome caused by a decision. For an offer, a randomised A/B test comparing profit per eligible assigned user over the same window can estimate incremental impact, with uncertainty. The Eurostat exercise shows why even the descriptive coefficient can change when the family definition changes.*

For a final self-check, explain one new case through **decision** → **data** → **unit and quality** → **method** → **possible action** → **measured outcome** → **limit**. Calculate S003's joined revenue and the fraud confusion matrix by hand. Then ask whether a prediction of gym no-shows is the same as the effect of sending reminders: one estimates who may not arrive, the other tests whether a chosen action changes attendance.

Evidence limits. The 25 September work has two recordings but this guide does not claim fresh complete audio listening. The available second recording on 29 September stops around Databricks introduction, not proof of a complete tutorial. The 6 October Data Lake chapter is supported by slides without a matching oral segment, and the afternoon file mainly concerns group work. The 13 October explanation is

from L4 slides and ZIP, with no local audio/transcript. L4 p.41 announces a 15-question warm-up but does not supply its questions or establish a future assessed format. Broad reading lists on Canvas are resources, not evidence that entire books are required for the next task.

Four linked readings and their proper limits

The course Reading Materials page offers books and four McKinsey articles. Their availability does **not** make every whole book compulsory for the next subcomponent. These articles can sharpen a business answer when read for their own question and date.

- *From raw data to real profits* (2024) connects a data asset to a customer need, defensible data or know-how, a product embedded in the user's workflow and a viable business model. Its Walmart Luminate, building-material KPI and pharma MVP cases show different routes; possession of data alone does **not** establish monetisation. Test privacy, IP rights, pricing, sales capability and scale.

- *The state of AI in 2023* reports an April 2023 survey of 1,684 respondents, with roughly a third reporting generative-AI use in its sample. It describes a gap in mitigation of inaccuracy and associations between self-described high performers and innovation/MLOps. These are 2023 self-reports and associations, **not 2026 adoption rates or causal proof** that MLOps creates performance. Link it to the distinction among technical use, controls and business value.

- *The data dividend: fueling generative AI* (2023) proposes seven actions from the use case and value to controls across source → preprocessing → prompt → output, including personal data, engineering, KPIs and cost management. Taker/Shaper/Maker describe different building choices. A vector database may serve a retrieval design; it is **not a prerequisite for every AI project**. Choose the smallest architecture that allows the decision and its checks.

- *Adopting a smart data mindset in a world of big data* (2021) argues for process experts and informative physical features before indiscriminate ML. Consulting cases include a virtual flowmeter, a dryer model using Darcy–Weisbach and shorter melt time. Reported +20% throughput, +8% and –10% are **case results**, not universal benchmarks. Ask what was measured, against which baseline and whether the process expert's insight transfers to this firm.

How the separate 80% brief relates to the concepts

The official Canvas brief (file 131911, pp.2–4) asks for an **executive report to a medium-sized company deciding whether to invest in Big Data and AI**. It requests business opportunities, critical success factors, risks and limits, impact on managerial decisions, digital transformation potential and a final recommendation. That is the portfolio/blog assignment, **not a confirmed in-class question**. To prepare without outsourcing authorship, use a **hypothetical** firm to frame one concrete decision, identify minimum data and a baseline, and define conditions for a bounded pilot. A conditional recommendation may say: proceed with one use case only after quality and rights checks; expand if a fair comparison shows better service or margin. The actual submission must be the student's own research and writing. The brief mentions a general 10% word-count tolerance but its question also says “3,200 words maximum”; follow the stricter instruction or ask the tutor before submission. Its template, .docx and Harvard-reference instructions govern that separate portfolio, not these study exercises.

Assessment-source note. The Canvas course heading identifies HFARM502, while the Blog brief and one home-page table cell print HFARM512. This is a discrepancy in the official materials; the title, lecturer and assignment identify Big Data & AI in Business.